# Prompts y respuestas IA

Álvaro Arcís Reverte y Alejandro Nicolás Navarro

Máster Universitario en Inteligencia Artificial
Curso 2026–2027

**Prompt**

Prepara un archivo README inicial, teniendo en cuenta lo pedido.

**Respuesta IA** Claude Code (Claude Opus 5.5), CLI en Windows

```
# Predicción Multiclase de Riesgo Cardiovascular en Población Adulta
> **Máster Universitario en Inteligencia Artificial - Universidad de
Murcia (UMU)**
> **Asignatura:** Machine Learning | **Curso:** 2026/2027
> **Colaboración clínica:** Hospital Morales Meseguer

---

##   Descripción del Proyecto

Las enfermedades cardiovasculares representan una de las principales
causas de morbimortalidad a nivel global. Este proyecto tiene como
objetivo diseñar, entrenar y evaluar modelos predictivos de Machine
Learning capaces de clasificar con alta precisión y fiabilidad clínica el
nivel de riesgo cardiovascular en una cohorte adulta de **2.254
pacientes**.

La variable objetivo (`riesgo_cardiovascular`) contempla tres niveles de
estratificación:
* **Clase 0:** Bajo Riesgo
* **Clase 1:** Riesgo Moderado
* **Clase 2:** Alto Riesgo

El repositorio recoge el flujo de trabajo end-to-end: desde el análisis
exploratorio de datos (EDA) y la mitigación de problemáticas de calidad
del dato (imputación, outliers, desbalanceo, escalado), hasta el ajuste
de hiperparámetros, validación cruzada y comparación estadística de
clasificadores base y ensambles.

---

##   Integrantes del Equipo

| Nombre y Apellidos | Usuario de GitHub | Correo Institucional |
| :--- | :--- | :--- |
| *[Nombre Miembro 1]* | `@usuario1` | `usuario1@um.es` |
| *[Nombre Miembro 2]* | `@usuario2` | `usuario2@um.es` |
| *[Nombre Miembro 3]* | `@usuario3` | `usuario3@um.es` |

---

##   Estructura del Repositorio

El proyecto se organiza bajo una estructura modular orientada a la
reproducibilidad científica:
```

```text
  data/
      raw/                          # Dataset original
(enfermedad_cardiovascular.csv)
      processed/                    # Datasets limpios o transformados (si
aplica)
  docs/                             # Documentación técnica y entregables
      memoria_tecnica.pdf           # Memoria técnica maquetada (máx. 15
páginas)
      uso_etico_ia.pdf              # Registro de prompts y reflexión
crítica de IA
      video_link.txt                # Enlace al vídeo explicativo (máx. 7
min)
  notebooks/                        # Jupyter Notebooks de desarrollo y
análisis
      01_eda_calidad_datos.ipynb # Análisis exploratorio y detección de
problemáticas
      02_preprocesamiento.ipynb  # Transformaciones, codificación e
imputación
      03_modelado_evaluacion.ipynb# Entrenamiento, ajuste de
hiperparámetros y métricas
      04_test_estadisticos.ipynb # Comparación estadística de modelos
(opcional)
  src/                              # Código fuente refactorizado y
reutilizable
      __init__.py
      data_loader.py                # Carga y comprobación de integridad
      preprocessing.py             # Pipelines de preprocesamiento
(Scikit-Learn)
      models.py                     # Definición y pipelines de algoritmos
      evaluation.py                 # Cálculo de métricas y matrices de
confusión
  .gitignore                        # Filtro de ficheros innecesarios
  environment.yml                   # Configuración del entorno Conda
(alternativa)
  requirements.txt                  # Fichero de dependencias fijadas
(versiones exactas)
  README.md                         # Documento principal del repositorio
```

**Análisis**

README inicial preparado, incluyendo descripción del proyecto, integrantes, estructura de carpetas y archivos. Se rellena con los datos de los miembros y la estructura del proyecto se cambiará.

**Prompt**

```
lee el proyecto y recomiendame una estructura para los archivos, crea los
archivos y las carpetas necesarias, pero ni se te ocurra resolverlos, e
incluye esta interacción al Uso_IA
```

**Respuesta IA** Claude Code (Claude Opus 5.5), CLI en Windows

```
Tras leer el enunciado, las instrucciones de entrega, el dataset y el
README, propuso y creó la siguiente estructura (solo esqueletos vacíos,
sin resolver ningún apartado):

- data/raw/            -> se movió aquí enfermedad_cardiovascular.csv
(git mv)
- data/processed/      -> vacío (.gitkeep)
- notebooks/           -> 01_eda, 02_preprocesamiento, 03_modelado,
04_evaluacion, 05_test_estadisticos (.ipynb), cada uno solo con títulos
de sección y celdas "# TODO"
- src/                 -> __init__, config, data_loader, preprocessing,
models, evaluation, statistical_tests (.py), solo con un docstring que
describe su responsabilidad y "TODO"
- results/figures/, results/tables/, models/ -> vacíos (.gitkeep)
- docs/decisiones.md   -> tabla para registrar decisiones de diseño y
avances
- docs/memoria/, docs/uso_etico_ia/ -> vacíos (.gitkeep)
- docs/video.md        -> plantilla para el enlace del vídeo
- requirements.txt     -> vacío, con instrucciones para rellenarlo con
pip freeze
- .gitignore           -> entornos virtuales, cachés, checkpoints,
modelos y auxiliares de LaTeX
- README.md            -> se rellenó la sección "Estructura del
Repositorio" y se añadió una sección "Reproducción" pendiente
```

**Análisis**

Se prepara la estructura de carpetas y archivos del proyecto, incluyendo los esqueletos vacíos para cada sección para facilitar la organización y el desarrollo posterior.

Conversación Alejandro para el EDA:
**[Ver conversación interactiva completa (HTML renderizado)]**

**Análisis**

En el enlace se sitúa la conversación mantenida con el LLM para la resolución de problemáticas de calidad del dato, incluyendo prompts, respuestas resumidas y análisis crítico.

**Prompt**

en visual studio code (.ipynb) cuando muestro, por ejemplo, un dataframe, se cortan las columnas o las filas a mitad y lo mismo ocurre con los print largos. Cómo puedo ver la salida completa?

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

Este problema ocurre por dos razones: las limitaciones propias de Pandas (para
no colapsar la memoria) y las limitaciones de la interfaz de VS Code (para no
ralentizar el editor).

Aquí tienes las soluciones para ambos casos:

1. Para DataFrames de Pandas (Filas y Columnas cortadas)

Pandas viene configurado por defecto para truncar tablas grandes. Puedes cambiar
esta configuración ejecutando esto en una celda al principio de tu notebook:

```
import pandas as pd

# Mostrar todas las columnas
pd.set_option('display.max_columns', None)

# Mostrar todas las filas (¡Cuidado si tienes millones de filas!)
pd.set_option('display.max_rows', None)

# Mostrar el contenido completo de cada celda (que no corte el texto largo)
pd.set_option('display.max_colwidth', None)
```

Consejo Pro para VS Code:
VS Code tiene un visor de datos integrado excelente.

1. Haz clic en el botón "Variables" en la barra superior del notebook (al lado
   de "Clear All Outputs").
2. Busca tu DataFrame y haz clic en el icono pequeño que parece una tabla a la
   izquierda del nombre de la variable.
   Se abrirá una pestaña interactiva donde puedes ordenar, filtrar y ver todos
   los datos sin recortar.

2. Para salidas de texto largas (print())

```
Si haces un print() muy largo, VS Code a veces corta el texto o le pone
una
barra de desplazamiento molesta.

Opción A: Desactivar el scroll (Hacer que se vea todo hacia abajo)

1.  Pasa el cursor por el margen izquierdo de la celda de salida (al lado
de
    donde aparece el texto).
2.  Haz clic en los tres puntos (...) que aparecen o haz clic derecho
sobre la
    salida.
3.  Selecciona "Toggle Output Scrolling" (Alternar desplazamiento de
salida).
    Esto expandirá la celda para que muestre todo el texto en lugar de
    recortarlo en una ventanita pequeña.

Opción B: Cambiar el límite de líneas en la configuración de VS Code

Por seguridad, VS Code limita el texto plano a unas 100 líneas por celda
para no
trabarse. Puedes aumentarlo:

1.  Ve a Configuración: Ctrl + , (en Windows/Linux) o Cmd + , (en Mac).
2.  En la barra de búsqueda escribe: notebook text line limit.
3.  Busca la opción: Notebook > Output: Text Line Limit.
4.  Aumenta el número (por defecto suele ser 100, puedes poner 500, 1000
o más).

3. Solución rápida en código para un print puntual

Si solo quieres imprimir un texto muy largo o un DataFrame como texto
completo
una sola vez sin cambiar la configuración global:

# Para DataFrames:
print(df.to_string())

# Para textos gigantes (evitar que la UI se congele guardándolo en un
archivo temporal):
with open("salida.txt", "w", encoding="utf-8") as f:
    f.write(str(tu_variable_gigante))
# Y luego lo abres directamente en VS Code con Ctrl+O
```

**Análisis**

Se acepta el código para poder visualizar los dataframes que pandas corta por defecto, dejándolo como código para descomentar si se necesita.

**Prompt**

cómo se lee una matriz de correlación? hay diferencia a la hora de analizar correlacion entre variables y entre la variable target?

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

```
Para entender una matriz de correlación sin perderte, la regla de oro es
dividirla en dos zonas completamente distintas:

1.  La relación entre tus variables predictoras y el TARGET (la fila o
columna
    de la variable a predecir).
2.  La relación entre las variables predictoras ENTRE SÍ (el resto de
celdas de
    la matriz).

Lo que en una zona es excelente, en la otra puede ser un problema grave.

Lo básico: ¿Qué significa el número? (Coeficiente de -1 a 1)

  - Cercano a 1 (Positivo fuerte): Se mueven en la misma dirección. Si el
  valor
    de una variable sube, el de la otra también tiende a subir.
  - Cercano a -1 (Negativo fuerte): Se mueven en direcciones opuestas. Si
  el
    valor de una variable sube, el de la otra tiende a bajar (relación
    inversa).
  - Cercano a 0: No hay relación lineal/monótona. Lo que le ocurra a una
    variable no nos dice absolutamente nada sobre el comportamiento de la
    otra.

Zona 1: Variables Predictoras vs. TARGET

Aquí buscas responder: ¿Esta variable me sirve para predecir lo que
quiero
estimar?

  - ¿Qué buscas aquí? Quieres números lo más alejados de 0 posible (tanto
    fuertemente positivos como fuertemente negativos).
      - Un valor alto positivo indica un factor de riesgo o acelerador
      directo.
      - Un valor alto negativo indica un factor protector o freno directo.
      Ambos
        son igual de útiles para el algoritmo.
  - ¿Cuándo es "malo" aquí?
      - Cuando el valor está muy cerca de 0.00.
      - Significa que esa variable, de forma aislada, apenas tiene poder
      de
        asociación con el target. Si todas las variables de un dataset
        tuvieran
```

```
        correlación cercana a 0 con el objetivo, el modelo difícilmente
        aprendería un patrón útil.

Zona 2: Variables Predictoras ENTRE SÍ

Aquí buscas responder: ¿Tengo variables repetidas que aportan la misma
información?

  - ¿Qué buscas aquí? En general, en Machine Learning, quieres números
  cercanos
    a 0 (variables independientes entre sí). Esto garantiza que cada
    columna
    aporta un dato nuevo y distinto al conjunto.
  - ¿Cuándo es "malo" aquí?
      - Cuando dos variables predictoras tienen una correlación muy alta
      entre
        sí (típicamente superior a 0.80 o inferior a -0.80). Este
        fenómeno se
        conoce como Multicolinealidad.
      - ¿Por qué es un problema la multicolinealidad?
        1.  Confunde a ciertos modelos (especialmente lineales como
        Regresión
            Lineal o Logística): Los algoritmos no pueden distinguir a
            cuál de
            las dos variables atribuirle el peso en la predicción,
            volviendo los
            coeficientes matemáticos muy inestables.
        2.  Introduce redundancia innecesaria: Estás duplicando
        información sin
            ganar capacidad predictiva, aumentando el coste computacional
            del
            modelo.

Resumen visual: ¿Qué buscar en cada parte de la matriz?

| Zona de la Matriz         | Lo ideal (Lo que quieres ver)
| Lo problemático (Lo que debes vigilar)
|
| :------------------------ |
:-------------------------------------------------------------------------------------
|
:-------------------------------------------------------------------------------------
|
| **Variable vs. Target**   | **Lejos de 0** (valores altos positivos o
negativos, ej. $> 0.25$ o $< -0.25$). Indican buena capacidad para
predecir el objetivo. | **Cerca de 0** (ej. entre $-0.05$ y $0.05$). La
variable no aporta información relevante de forma individual para
predecir el target. |
```

```
| **Variable vs. Variable** | **Cerca de 0** (habitualmente entre $-0.30$
y $0.30$). Cada variable mide aspectos distintos e independientes.
| **Muy cerca de 1 o -1** (magnitudes $> 0.80$). Hay variables
redundantes (**Multicolinealidad**) que pueden desestabilizar el modelo.
|
```

## Análisis

Se acepta la explicación de la tabla de correlación y la explicación de valores a tener en cuenta entre variables vs variables y variables vs target.

## Prompt

```
# ------------------------------------------------------------------------------
# 1. MATRIZ DE CORRELACIÓN DE SPEARMAN (NUMÉRICAS + TARGET)
# ------------------------------------------------------------------------------
plt.figure(figsize=(18, 14))
corr_matrix = df[NUM_COLS + [TARGET_COL]].corr(method="spearman")
mask = np.triu(np.ones_like(corr_matrix, dtype=bool))

sns.heatmap(
    corr_matrix,
    mask=mask,
    cmap="vlag",
    center=0,
    annot=True,
    fmt=".2f",
    annot_kws={"size": 8},
    linewidths=0.5,
    cbar_kws={"shrink": 0.8},
)
plt.title(
    "Matriz de Correlación de Spearman (Variables Numéricas y Target)",
    fontsize=14,
    fontweight="bold",
    pad=15,
)
plt.show()

# ------------------------------------------------------------------------------
# 2. TOP VARIABLES NUMÉRICAS CON MAYOR PODER DISCRIMINATORIO EMPÍRICO
# ------------------------------------------------------------------------------
# Calculamos la correlación de Spearman de cada variable numérica con el target
# y seleccionamos las 8 de mayor magnitud absoluta (positivas o protectoras/negativas)
corr_with_target = df[NUM_COLS].corrwith(df[TARGET_COL], method="spearman")
top_features = corr_with_target.abs().sort_values(ascending=False).head(8).index

print("=" * 70)
print(
    "TOP 8 VARIABLES NUMÉRICAS MÁS ASOCIADAS EMPÍRICAMENTE AL RIESGO CARDIOVASCULAR"
)
print("=" * 70)
for feat in top_features:
    r_val = corr_with_target[feat]
    tipo = "Factor de Riesgo (+)" if r_val > 0 else "Factor Protector (-)"
    print(f" • {feat:28s}: Spearman r = {r_val:+.3f}  ({tipo})")

# Visualización mediante Boxplots estratificados por nivel de riesgo
fig, axes = plt.subplots(2, 4, figsize=(18, 11))
axes = axes.flatten()

class_labels_short = ["0 (Bajo)", "1 (Moderado)", "2 (Alto)"]

for idx, col in enumerate(top_features):
```

```
    r_val = corr_with_target[col]
    sns.boxplot(
        x=TARGET_COL,
        y=col,
        data=df,
        ax=axes[idx],
        palette="Blues",
        hue=TARGET_COL,
        legend=False,
    )
    axes[idx].set_title(
        f"{col}\n(Spearman r = {r_val:+.2f})", fontsize=11, fontweight="bold"
    )
    axes[idx].set_xlabel("Nivel de Riesgo Cardiovascular")
    axes[idx].set_xticklabels(class_labels_short)
    axes[idx].set_ylabel(col)

plt.suptitle(
    "Distribución de las 8 Variables Numéricas más Correlacionadas empíricamente",
    y=1.02,
    fontsize=14,
    fontweight="bold",
)
plt.tight_layout()
plt.show()
```

No es un poco innecesario este codigo por volver a calcular las correlacion de spearman si ya tienes la matriz de correlación de antes? o es mejor porque es más preciso?

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

Tienes toda la razón: es completamente innecesario y redundante. No es más
preciso en absoluto; el cálculo matemático y el resultado numérico son exactamente los mismos.

¿Por qué es redundante?

En el paso 1 ya calculaste la matriz completa:

```
corr_matrix = df[NUM_COLS + [TARGET_COL]].corr(method="spearman")
```

Dentro de corr_matrix, la columna (o fila) correspondiente a TARGET_COL ya
contiene exactamente la correlación de Spearman de cada variable numérica con el
target.

Volver a ejecutar df[NUM_COLS].corrwith(...) en el paso 2 obliga a pandas a
volver a ordenar (rankear) todos los datos y recalcular las operaciones matemáticas desde cero, lo cual:

1. Desperdicia tiempo de cómputo (Spearman requiere ordenar los datos, lo que
   en datasets medianos/grandes es costoso).

```
2.  Viola el principio DRY (Don't Repeat Yourself).

Cómo simplificarlo

Puedes reemplazar esa línea extrayendo directamente la serie de la matriz
que ya
calculaste:

#
------------------------------------------------------------------------------
# 2. TOP VARIABLES NUMÉRICAS CON MAYOR PODER DISCRIMINATORIO EMPÍRICO
#
------------------------------------------------------------------------------
# En lugar de recalcular con .corrwith():
# corr_with_target = df[NUM_COLS].corrwith(df[TARGET_COL],
method="spearman")

# Simplemente extraes la columna del target para las variables numéricas:
corr_with_target = corr_matrix.loc[NUM_COLS, TARGET_COL]

top_features =
corr_with_target.abs().sort_values(ascending=False).head(8).index

El resto de tu código funcionará exactamente igual, pero de forma más
limpia,
idiomática y eficiente.
```

**Análisis**

Al notar que la correlación se calculaba dos veces y dudar de si aportaba mayor precisión, se confirmó con esta consulta que el segundo cálculo era redundante e innecesario, pasando a extraer los valores directamente de la matriz previa para simplificar el código.

**Prompt**

```python
for idx, col in enumerate(top_features):
    r_val = corr_with_target[col]
    sns.boxplot(
        x=TARGET_COL,
        y=col,
        data=df,
        ax=axes[idx],
        palette= "Blues",
        hue=TARGET_COL,
        legend=False,
    )
```

Haz que la paleta sea roja si la correlación es positiva y azul si es negativa.

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

Aquí tienes el bucle modificado. Puedes asignar dinámicamente la paleta ("Reds" si es positiva o "Blues" si es negativa) evaluando el valor de r_val:

```
for idx, col in enumerate(top_features):
    r_val = corr_with_target[col]

    # Paleta dinámica: Rojo si aumenta el riesgo (+), Azul si es
    protector (-)
    palette_color = "Reds" if r_val > 0 else "Blues"

    sns.boxplot(
        x=TARGET_COL,
        y=col,
        data=df,
        ax=axes[idx],
        palette=palette_color,
        hue=TARGET_COL,
        legend=False,
    )
    axes[idx].set_title(
        f"{col}\n(Spearman r = {r_val:+.2f})", fontsize=11,
        fontweight="bold"
    )
    axes[idx].set_xlabel("Nivel de Riesgo Cardiovascular")
    axes[idx].set_xticklabels(class_labels_short)
    axes[idx].set_ylabel(col)
```

¿Qué hace este cambio?

- Si r > 0 (Factor de Riesgo): utiliza la gama "Reds", donde los niveles de
  riesgo van subiendo en tonos de rojo.
- Si r \le 0 (Factor Protector): utiliza la gama "Blues", manteniendo la
  escala de azules.

**Análisis**

Se acepta la sugerencia, pero sin hacer la variable auxiliar.

**Prompt**

Tengo una base de datos sobre Predicción Multiclase de Riesgo Cardiovascular en
Población Adulta para clasificar a los pacientes en tres niveles de riesgo
cardiovascular (Clase 0: Bajo Riesgo, Clase 1: Riesgo Moderado y Clase 2: Alto
Riesgo). Las variables son:

edad (Numérico): Edad del paciente expresada en años cumplidos.

presion_sistolica (Numérico): Presión arterial sistólica medida en reposo (mmHg).

presion_diastolica (Numérico): Presión arterial diastólica medida en reposo
(mmHg).

colesterol_total (Numérico): Nivel de colesterol total en suero (mg/dL).

colesterol_hdl (Numérico): Nivel de colesterol de alta densidad o 'colesterol
bueno' (mg/dL).

colesterol_ldl (Numérico): Nivel de colesterol de baja densidad o 'colesterol
malo' (mg/dL).

trigliceridos (Numérico): Concentración sérica de triglicéridos (mg/dL).

glucosa_ayunas (Numérico): Nivel de glucosa en sangre tras ayuno nocturno (mg/dL).

indice_masa_corporal (Numérico): Índice de masa corporal calculado como peso/talla$^2$ (kg/m$^2$).

frecuencia_cardiaca_reposo (Numérico): Frecuencia cardíaca medida en reposo
(latidos por minuto).

horas_sueno_diarias (Numérico): Promedio de horas de descanso nocturno declaradas por día.

consumo_alcohol_semanal (Numérico): Unidades de bebida estándar de alcohol
consumidas semanalmente.

anos_fumador (Numérico): Tiempo acumulado de exposición al tabaco expresado en
años.

proteina_c_reactiva (Numérico): Concentración de proteína C reactiva ultrasensible (mg/L).

acido_urico (Numérico): Nivel sérico de ácido úrico (mg/dL).

clearance_creatinina (Numérico): Tasa de filtrado glomerular / depuración de
creatinina (mL/min).

```
frecuencia_ejercicio_semanal (Numérico): Días a la semana con actividad
física
moderada o intensa.

perimetro_cintura (Numérico): Circunferencia abdominal medida en
centímetros.

hemoglobina_glicosilada (Numérico): Porcentaje de hemoglobina glicosilada
HbA1c
en sangre (%).

fumador_actual (Booleano): Indica el hábito tabáquico activo (1: Sí, 0:
No).

hipertension_previa (Booleano): Diagnóstico previo confirmado de
hipertensión
arterial (1: Sí, 0: No).

diabetes_mellitus (Booleano): Diagnóstico previo de diabetes mellitus
tipo 2 (1:
Sí, 0: No).

tratamiento_estatinas (Booleano): Uso habitual de fármacos
hipolipemiantes /
estatinas (1: Sí, 0: No).

uso_antihipertensivos (Booleano): Uso habitual de medicamentos para el
control
presivo (1: Sí, 0: No).

tipo_alimentacion (Nominal): Patrón dietético principal del paciente.
Valores
posibles: 'Mediterránea', 'Occidental', 'Vegetariana', 'Baja en
carbohidratos'.

nivel_actividad (Nominal): Grado habitual de actividad física diaria.
Valores
posibles: 'Sedentario', 'Ligeramente activo', 'Moderadamente activo',
'Muy
activo'.

antecedentes_familiares_tipo (Nominal): Presencia de eventos
cardiovasculares en
familiares de primer grado. Valores posibles: 'Ninguno', 'Materno',
'Paterno',
'Ambos'.

riesgo_cardiovascular (Objetivo): Variable target de clasificación en 3
categorías (0: Bajo riesgo, 1: Riesgo moderado, 2: Alto riesgo).
```

Quiero que me digas valores en los que suelen estar estas variables y qué errores sería conveniente revisar.

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

Para preparar adecuadamente esta base de datos antes de entrenar un modelo de
Machine Learning, es fundamental validar tanto los rangos clínicos plausibles
como la coherencia lógica entre variables.

A continuación, tienes una guía detallada dividida en dos partes: rangos de
referencia y errores/inconsistencias clave a revisar.

1. Rangos de Valores Típicos y Plausibles

A continuación se presentan los valores divididos en rangos normales, rangos
habituales en la práctica clínica y límites extremos que indicarían un posible
error de captura:

| Variable | Rango Normal / Óptimo
| Rango Típico en Adultos | Alerta: Posible Error de Datos
|
| :---------- | :----------
| :---------- |
:---------- |
| **edad** | 18 - 65 años
| 18 - 95 años | $< 18$ (si es solo adultos) o $> 110$
|
| **presion_sistolica** | 90 - 120 mmHg
| 100 - 180 mmHg | $< 70$ (shock) o $> 240$ mmHg
|
| **presion_diastolica** | 60 - 80 mmHg
| 60 - 110 mmHg | $< 40$ o $> 140$ mmHg
|
| **colesterol_total** | $< 200$ mg/dL
| 130 - 320 mg/dL | $< 80$ o $> 500$ mg/dL
|
| **colesterol_hdl** | $> 40$ (hombres) / $> 50$
(mujeres) | 25 - 85 mg/dL | $< 15$ o $> 120$ mg/dL
|
| **colesterol_ldl** | $< 100$ mg/dL
| 70 - 220 mg/dL | $< 30$ o $> 350$ mg/dL
|

```
| **trigliceridos**                  | $< 150$ mg/dL
| 60 - 350 mg/dL          | $< 30$ o $> 1000$ mg/dL
|
| **glucosa\_ayunas**                | 70 - 99 mg/dL
| 70 - 250 mg/dL          | $< 40$ (hipoglucemia severa) o $> 400$ mg/dL
|
| **indice\_masa\_corporal**         | 18.5 - 24.9 kg/m²
| 18 - 45 kg/m²           | $< 13$ o $> 65$ kg/m²
|
| **frecuencia\_cardiaca\_reposo**   | 60 - 100 lpm
| 50 - 110 lpm            | $< 35$ o $> 180$ lpm
|
| **horas\_sueno\_diarias**          | 7 - 9 horas
| 4 - 10 horas            | $< 2$ o $> 16$ horas
|
| **consumo\_alcohol\_semanal**      | 0 - 7 (mujeres) / 0 - 14 (hombres)
| 0 - 30 UBEs\*           | $< 0$ o $> 80$ UBEs semanales
|
| **anos\_fumador**                  | 0 años
| 0 - 50 años             | $< 0$ o mayor que `edad - 10`
|
| **proteina\_c\_reactiva (PCR)**    | $< 1.0$ mg/L (bajo riesgo)
| 0.1 - 10 mg/L           | $> 20$ mg/L (suele indicar infección aguda,
no riesgo vascular basal) |
| **acido\_urico**                   | 3.5 - 7.2 mg/dL
| 2.5 - 10 mg/dL          | $< 1.5$ o $> 15$ mg/dL
|
| **clearance\_creatinina**          | 90 - 130 mL/min
| 30 - 140 mL/min         | $< 5$ o $> 200$ mL/min
|
| **frecuencia\_ejercicio\_semanal** | 3 - 5 días
| 0 - 7 días              | $< 0$ o $> 7$ días
|
| **perimetro\_cintura**             | $< 80$ (mujeres) / $< 94$
(hombres) | 65 - 130 cm             | $< 45$ o $> 180$ cm
|
| **hemoglobina\_glicosilada**       | 4.0% - 5.6%
| 4.5% - 11%              | $< 3.5\%$ o $> 16\%$
|

*UBE = Unidad de Bebida Estándar (aprox. 1 caña de cerveza, 1 copa de
vino o 1
chupito).

2. Errores de Coherencia Cruzada (Cruciales para Limpieza)

En variables médicas, los datos pueden estar individualmente en rango,
pero ser
fisiológicamente imposibles o contradictorios al compararlos entre sí:
```

```
A. Presión Arterial

  - Error crítico: presion_diastolica >= presion_sistolica. La sistólica
  siempre
    debe ser superior.
  - Presión de pulso no plausible: La diferencia (presion_sistolica -
    presion_diastolica) rara vez es menor a 20 mmHg o mayor a 100 mmHg en
    reposo.

B. Coherencia en el Perfil Lipídico

  - Ecuación de Friedewald: En condiciones normales, el colesterol total
  se
    aproxima con:
    \text{Colesterol Total} \approx \text{LDL} + \text{HDL} +
    (\text{Triglicéridos} / 5)
    Si la suma de \text{LDL} + \text{HDL} supera ampliamente al
    colesterol_total, hay un error de registro.

C. Tabaco y Edad

  - anos_fumador >= edad: Imposible.
  - anos_fumador > (edad - 10): Muy poco probable (indicaría que empezó a
  fumar
    con menos de 10 años).
  - Contradicción de hábito: Pacientes con fumador_actual == 0 pero
  anos_fumador
    > 0 representan ex-fumadores (esto es correcto, pero conviene
    definirlo);
    sin embargo, fumador_actual == 1 con anos_fumador == 0 suele ser un
    error (a
    menos que haya empezado hace menos de un año).

D. Diabetes y Glucemia

  - Si diabetes_mellitus == 0, pero hemoglobina_glicosilada >= 6.5% y
    glucosa_ayunas >= 126 mg/dL, es probable que el paciente sea un
    diabético no
    diagnosticado o haya un error en la etiqueta binaria.
  - Si diabetes_mellitus == 1, pero tiene glucosa_ayunas y
    hemoglobina_glicosilada en rangos extremadamente bajos sin
    medicación,
    convendría revisarlo.

E. Hipertensión y Medicación

  - Pacientes con uso_antihipertensivos == 1 que tienen
  hipertension_previa == 0
    (raro, salvo uso off-label para otras patologías como migraña o
    insuficiencia cardíaca).
```

```
F. Actividad Física

  - Inconsistencia entre nivel_actividad == 'Sedentario' y
    frecuencia_ejercicio_semanal >= 5.
  - Inconsistencia entre nivel_actividad == 'Muy activo' y
    frecuencia_ejercicio_semanal == 0.

G. Antropometría (IMC vs. Cintura)

  - Un indice_masa_corporal > 35 (obesidad moderada/severa) acompañado de
  un
    perimetro_cintura < 70 cm indica casi con seguridad un error en las
    unidades
    (por ejemplo, registrar la cintura en pulgadas en lugar de
    centímetros).

3. Buenas Prácticas adicionales para tu Modelo

1.  Codificación de Variables Nominales:
      - antecedentes_familiares_tipo y tipo_alimentacion deben tratarse
      con
        One-Hot Encoding.
      - nivel_actividad tiene un orden intrínseco (Sedentario \to
      Ligeramente
        \to Moderadamente \to Muy activo), por lo que un Ordinal Encoding
        (0, 1, 2, 3) preservará mejor esa jerarquía.
2.  Distribución del Target (riesgo_cardiovascular):
      - Comprueba el desbalance de clases. En salud, la Clase 2 (Alto
      Riesgo)
        suele tener muchas menos muestras que la Clase 0. Si hay
        desbalance
        severo, evalúa métricas como Macro F1-Score o PR-AUC multiclase
        en lugar
        de Accuracy, y utiliza técnicas como SMOTE o ponderación de
        clases
        (class_weight='balanced').
3.  Valores Nulos Encubiertos:
      - Busca números como -1, 999 o 0 en variables como
      clearance_creatinina,
        horas_sueno_diarias o presion_sistolica, que a veces se
        introducen en
        bases de datos hospitalarias para indicar "no registrado".
```

**Análisis**

En cuanto a esta propuesta inicial de la IA para detectar problemáticas y establecer algunos rangos para detectar valores erróneos o atípicos, hay opinión dividida. Por una parte, se aceptan y se toman en cuenta algunas propuestas sobre valores y rangos a comprobar. Algunos ya los habíamos tenido en cuenta, como puede ser

comprobar si hay menores de edad en los ejemplos o comprobar que el consumo de alcohol semanal no es negativo, pero algunos otros son propuestas interesantes que no se habían tenido en cuenta, aunque falta comprobar si comprobación tienen sentido. También revela una fórmula por la cual se relacionan los dos tipos de colesterol y el colesterol total, revelando que también la columna *trigliceridos* actúa. Sin embargo, se descartan algunas propuestas como marcar ciertos valores extremos como errores, ya que eliminar valores atípicos pueden ser valores valiosos para poder aprender a detectar el riesgo alto, y más si es un problema en el ámbito de la medicina. Habrá que determinar qué valores atípicos conservar.

**Prompt**

Muchas de las variables que me has indicado como una alerta de posible error,si estoy haciendo un modelo para predecir el riesgo cardiovascular, no crees que son interesantes mantenerlas porque esos atípicos podrían ayudar a ser el detonante para detectar el riesgo?

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

```
Es una observación completamente acertada y muy perspicaz desde el punto
de
vista clínico. En medicina, los eventos graves (infartos, ictus) suelen
ocurrir
precisamente en la "cola" de la distribución: el paciente que tiene 210
mmHg de
tensión sistólica o 9.5% de hemoglobina glicosilada es exactamente el que
debe
clasificarse como Alto Riesgo (Clase 2).

Eliminar estos valores a ciegas ("tratar los outliers" de forma estándar)
arruinaría la capacidad predictiva del modelo.

Sin embargo, hay una diferencia crítica entre dos tipos de valores
extremos. El
objetivo no es borrar datos por ser altos, sino distinguir el riesgo
extremo del
"ruido biológicamente imposible" o del "ruido de confusión".

Aquí tienes cómo diferenciar lo que debes conservar de lo que debes
corregir o
descartar:

1. Lo que DEBES mantener (Atípicos Clínicos / Señales de Alto Riesgo)

Son valores muy elevados, pero compatibles con la vida y directamente
causantes
de daño cardiovascular. No los elimines ni los recortes
(capping/winsorizing) si
```

```
vas a usar modelos basados en árboles:

  - Presión sistólica de 190 - 220 mmHg: Es una crisis o urgencia
  hipertensiva.
    Es un predictor brutal de riesgo cardiovascular inminente.
  - Triglicéridos de 500 - 1000 mg/dL: Se asocia a hipertrigliceridemia
  severa
    (y riesgo de pancreatitis además de cardiovascular).
  - Glucosa en ayunas de 250 - 350 mg/dL o HbA1c de 11 - 13%: Diabetes
    gravemente descompensada; genera aterosclerosis acelerada.
  - Clearance de creatinina de 15 - 30 mL/min: Insuficiencia renal
  avanzada; la
    enfermedad renal crónica es uno de los mayores multiplicadores de
    riesgo
    cardiovascular conocidos.
  - IMC de 45 - 55: Obesidad mórbida grado III, factor de riesgo masivo.

2. Lo que DEBES corregir o eliminar (Errores que engañan al algoritmo)

Aquí el valor atípico no representa "más riesgo", sino un fallo en la
toma o
registro del dato. Si dejas estos valores, el modelo aprenderá patrones
absurdos:

  - Incompatibilidad física o biológica:
      - Una presion_sistolica de 320 mmHg o 30 mmHg en un paciente
      ambulatorio.
        A 320 revienta una arteria cerebral al instante; a 30 la persona
        está en
        parada cardiorrespiratoria, no haciéndose un chequeo de
        prevención.
      - presion_diastolica (p. ej., 110) mayor que la sistolica (p. ej.,
      90):
        Error humano al teclear la barra espaciadora o intercambiar las
        columnas.
  - Confusión de escalas/unidades (Muy común):
      - glucosa_ayunas con valor 6.5: El médico anotó el dato en mmol/L
      (usado
        en Europa/EE.UU.) en lugar de mg/dL (debería ser ~117 mg/dL). El
        modelo
        interpretará que el paciente tiene glucosa 6.5 mg/dL (estaría
        muerto de
        hipoglucemia).
      - perimetro_cintura de 36: Medido en pulgadas, no en centímetros
      (36
        pulgadas son ~91 cm).
  - Datos "centinela" o nulos camuflados:
      - clearance_creatinina = -1 o 999. Si el algoritmo lo toma como
      número
```

```
        continuo, un 999 parecerá un riñón superhumano cuando en realidad
        era un
        dato faltante.

3. El caso especial de la PCR (Proteína C Reactiva): El "Ruido de
Confusión"

La proteina_c_reactiva es el mejor ejemplo de por qué hay que tener
cuidado:

  - En riesgo cardiovascular se utiliza la PCR ultrasensible (PCR-us):
      - Bajo riesgo: < 1 mg/L
      - Riesgo moderado: 1 - 3 mg/L
      - Riesgo alto: > 3 mg/L (hasta unos 10 mg/L)
  - ¿Qué pasa si un paciente tiene PCR de 80 mg/L? No significa que tenga
  8
    veces más riesgo cardíaco que uno de 10. Significa que ese día tenía
    una
    neumonía, una infección bacteriana o una apendicitis. Si dejas ese
    valor sin
    contexto, el modelo puede asumir que una inflamación sistémica aguda
    es la
    causa primaria de riesgo cardiovascular a largo plazo, distorsionando
    el
    peso de la variable. Clínicamente, ante una PCR > 20 mg/L, la
    analítica
    cardiovascular suele descartarse y repetirse semanas después.

¿Cómo manejar esto con Machine Learning?

1.  Usa modelos robustos a valores extremos: Si mantienes estos valores
atípicos
    reales (como 210 mmHg de tensión o glucosas de 300), no utilices
    Regresión
    Logística o Redes Neuronales sin escalar, ya que los extremos
    desestabilizan
    los gradientes y coeficientes. Utiliza modelos basados en árboles de
    decisión (XGBoost, LightGBM, Random Forest), ya que a estos modelos
    solo les
    importa el orden de partición (>180 ya es alto, da igual si es 185 o
    240,
    caerán en la misma rama).
2.  Tu filtro no debe ser estadístico (Z\text{-score} > 3), debe ser de
    plausibilidad fisiológica: No quites un dato solo porque se aleje de
    la
    campana de Gauss. Quítalo únicamente si el valor es incompatible con
    que el
    paciente haya llegado caminando a la consulta.
```

**Análisis**

La información que aporta no es suficiente para detectar valores erroneos ni tomar decisiones en el dataset, es mejor investigar y consultar individualmente cada variable. Sin embargo, la consulta sirve para confirmar que no se debe eliminar los valores atípicos de forma estándar porque arruinaría la capacidad predictiva del modelo.

**Prompt**

colesterol hdl valores puede ser negativo?

**Respuesta IA** `Gemini Flash-Lite 3.5 en Gemini`

No, el valor del colesterol HDL (conocido como colesterol "bueno") no puede ser negativo.
• Valores mínimos lógicos: Los niveles de colesterol HDL en la sangre se miden en miligramos por decilitro (mg/dL) y el límite físico inferior es de 0 mg/dL, ya que no existe una cantidad menor de cero.
• Valores considerados bajos:
• En hombres: menos de 40 mg/dL (y se considera muy bajo por debajo de 35 mg/dL).
• En mujeres: menos de 50 mg/dL (y se considera muy bajo por debajo de 40 mg/dL).
• Si has visto un número negativo o extraño en una analítica: Generalmente se debe a un error de transcripción, un fallo en la lectura del equipo del laboratorio, un formato de celda alterado o un código de error informático, y no a que tu organismo tenga un nivel negativo de lipoproteínas.
Consulta con tu médico o con el laboratorio que realizó el análisis para que repitan la lectura o te aclaren la cifra exacta de tu perfil lipídico. Si te han entregado unos análisis recientes, dime:
• ¿Qué valor numérico exacto te aparece?
• ¿Hay otros valores alterados (como los triglicéridos o el colesterol LDL)?
Así podré orientarte mejor sobre lo que significa tu resultado.

**Análisis**

Al encontrarse este valor negativo y dudar de su validez, se aceptó la afirmación de que el colesterol HDL no puede ser biológicamente negativo, estableciendo correctamente el límite inferior en 0 mg/dL.

**Prompt**

y los triglicéridos pueden ser negativos?

**Respuesta IA** Gemini Flash-Lite 3.5 en Gemini

No, los triglicéridos no pueden ser negativos. En una analítica de sangre, los resultados miden la cantidad de una sustancia real presente en el organismo, por lo que el valor mínimo posible es cero (0 mg/dL), aunque un nivel de cero absoluto tampoco es biológicamente realista. Si ves un signo de resta o un valor negativo en tu informe, generalmente se debe a una de las siguientes razones:

- Es un guion o símbolo de separación: A veces, el sistema del laboratorio utiliza un guion antes del número o para separar el nombre de la prueba de su resultado (por ejemplo: Triglicéridos - 85 mg/dL), lo que puede confundirse con un signo "menos".
- Un error en el informe impreso: Puede tratarse de una errata tipográfica o un fallo de formato en la visualización del documento.
- Error de laboratorio: En casos extremadamente raros, si el cálculo se realiza de forma automatizada mediante ciertas fórmulas indirectas y otros valores están muy descompensados, el sistema podría arrojar un error técnico.

Para ayudarte a salir de dudas, ¿podrías transcribir exactamente cómo aparece escrito el valor en tu papel, o indicarme el resto de los resultados (como el colesterol total, LDL y HDL)?

**Análisis**

Al encontrarse este valor negativo y dudar de su validez, se aceptó la afirmación de que los triglicéridos no pueden ser biológicamente negativos, estableciendo correctamente el límite inferior en 0 mg/dL. La IA plantea que podría haberse colado un signo menos. Esta hipótesis se podría tener en cuenta a la hora de decidir qué estrategia aplicr con las variables cuyos valores no podían ser negativos, si se determina que realmente ha sido un error al escribir los datos.

**Prompt**

rango típico de presión sistólica y presión dialótica

**Respuesta IA** Gemini Flash-Lite 3.5 en Gemini

El rango típico o normal de la presión arterial en adultos se sitúa por debajo de 120/80 mm Hg (milímetros de mercurio).

- Presión sistólica (el número superior): Representa la fuerza de la sangre contra las paredes de las arterias cuando el corazón se contrae. Un valor normal o saludable es menor de 120 mm Hg (típicamente entre 90 y 120 mm Hg).
- Presión diastólica (el número inferior): Mide la presión en las arterias cuando el corazón se relaja entre latidos. Un valor normal o saludable es menor de 80 mm Hg (típicamente entre 60 y 80 mm Hg).

Clasificación general (según guías clínicas como la AHA/ACC)

- Normal: Menor de 120 / Menor de 80 mm Hg
- Elevada: Sistólica entre 120 y 129 y diastólica menor de 80 mm Hg • Hipertensión (Etapa 1): Sistólica entre 130 y 139 o diastólica entre 80 y 89 mm Hg
- Hipertensión (Etapa 2): Sistólica de 140 mm Hg o más, o diastólica de 90 mm Hg o más

• Crisis hipertensiva: Valores superiores a 180 / 120 mm Hg (requiere atención médica inmediata)
Puedes consultar más detalles y herramientas informativas en la guía oficial de MedlinePlus en español o revisar la tabla explicativa del Manual MSD.
Si lo deseas, dime:
• ¿Es una consulta para un adulto joven, de mediana edad o mayor?
• ¿Hay síntomas (como mareos o dolor de cabeza) o medicación de por medio?
Puedo darte información más específica sobre cómo se interpretan las lecturas.

**Análisis**

Los datos que aporta son correctos dadas las fuentes de las que lo ha sacado, pero no me despeja la duda suficiente para saber si los valores mínimos y máximos en estas dos presiones se podrían dar en la realidad.

**Prompt**

podría ocurrir que al medir la presión sistólica de un paciente los valores fuesen 52 o 231? y que la presión distólica fuese 30 o 122? O son valores que no se pueden dar en la realidad? Están en mmHg.

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

Sí, todos esos valores son posibles en la realidad y representan situaciones clínicas reales de extrema gravedad (tanto por ser peligrosamente bajas como críticamente altas). No son meros errores de medición, aunque siempre se deben confirmar.
La explicación médica para cada uno de estos extremos en mm Hg es la siguiente:
Valores de Presión Sistólica
• 52 mm Hg (Posible y crítico): Este valor representa una hipotensión extrema. En la práctica médica, se asocia directamente con un estado de shock (como el shock séptico, cardiogénico o hemorrágico), donde el corazón no tiene la fuerza suficiente o no hay suficiente volumen de sangre para mantener la presión. Es una emergencia médica de código rojo, ya que los órganos vitales no reciben suficiente oxígeno.
• 231 mm Hg (Posible y crítico): Este valor representa una crisis hipertensiva severa. Ocurre en pacientes con hipertensión grave descontrolada o durante eventos médicos agudos (como un ictus o una disección aórtica). Valores tan altos ponen al paciente en riesgo inminente de daño orgánico (infarto, derrame cerebral o fallo renal) y requieren atención médica inmediata para bajar la presión de forma controlada.
Valores de Presión Diastólica
• 30 mm Hg (Posible y crítico): Una presión diastólica tan baja se puede observar en casos de insuficiencia aórtica severa (donde la válvula del corazón no cierra bien y la sangre regresa), en estados de vasodilatación extrema (como en una reacción alérgica grave o anafilaxia) o en shock séptico.
• 122 mm Hg (Posible y crítico): Este valor se sitúa firmemente dentro de una crisis hipertensiva (cualquier cifra diastólica mayor de 120 mm Hg lo es). Indica que las arterias están soportando una resistencia y una tensión masivas incluso cuando el corazón está en reposo, lo que fatiga gravemente el sistema cardiovascular.

¿Qué se hace en la realidad ante estos valores?
Cuando un tensiómetro digital o manual muestra cifras tan extremas, el protocolo médico exige:
1. Verificar el estado del paciente: Si el paciente está inconsciente, mareado o tiene dolor en el pecho, el valor suele ser real.
2. Repetir la medición: Se vuelve a medir (a menudo en el otro brazo o con un equipo manual calibrado) para descartar que el brazalete estuviera mal colocado, que el paciente se moviera o que el aparato tuviera la batería baja. Si estás analizando un caso concreto, cuéntame:
• ¿El paciente presenta síntomas actuales como mareos, desmayos, dolor de cabeza o dolor en el pecho?
• ¿Se trata de un ejercicio académico/simulación o de una lectura real? Así podré darte información más orientada a lo que necesitas.

**Análisis**

Al hacer la consulta sobre los valores extremos, la IA confirmó que dichas cifras son biológicamente viables en escenarios clínicos críticos, por lo que se confirma que no se descarta ningún valor para la presión sistólica y diastólica.

**Prompt**

rango de colesterol hdl y colesterol ldl, cuando es preocupante o imposible

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

Los rangos de colesterol en sangre se miden en miligramos por decilitro (mg/dL).
Colesterol LDL (el ”malo”)
• Nivel óptimo: Menos de 100 mg/dL.
• Casi óptimo o aceptable: 100 – 129 mg/dL.
• Límite alto: 130 – 159 mg/dL.
• Alto: 160 – 189 mg/dL.
• Muy alto / Preocupante: 190 mg/dL o más (requiere atención médica inmediata y a menudo tratamiento con estatinas, ya que eleva drásticamente el riesgo cardiovascular).
• Metas estrictas: En personas con alto riesgo cardiovascular o que ya han sufrido un infarto, los médicos buscan tener un LDL por debajo de 70 mg/dL o incluso menor de 55 mg/dL.
Colesterol HDL (el ”bueno”)
• Bajo (preocupante):
• Menos de 40 mg/dL en hombres.
• Menos de 50 mg/dL en mujeres.
• Aceptable / Normal: 40–59 mg/dL en hombres y 50–59 mg/dL en mujeres.
• Nivel protector (óptimo): 60 mg/dL o más (actúa como factor protector contra enfermedades del corazón).
• Nota sobre extremos: Aunque el HDL es ”bueno”, niveles extremadamente altos (por encima de 90-100 mg/dL de forma patológica) no necesariamente otorgan más

protección y a veces se asocian con alteraciones genéticas raras.
¿Cuándo es preocupante o ïmposible¿
• Cuándo es preocupante:
• Un LDL muy elevado ( 190 mg/dL) o un HDL muy bajo combinado con factores de riesgo como tabaquismo, hipertensión, diabetes o antecedentes familiares de infarto precoz.
• Un LDL moderadamente alto que no baja a pesar de mejorar la dieta y hacer ejercicio.
• ¿Existen valores ïmposibles¿
• Cero de LDL: No es imposible biológicamente; de hecho, los recién nacidos tienen niveles muy bajos de LDL (alrededor de 30-40 mg/dL) y el cuerpo puede funcionar con niveles reducidos si se toman fármacos potentes (como inhibidores de PCSK9 o estatinas), aunque en la práctica clínica un LDL de 0 no es un objetivo natural ni habitual.
• Cero de HDL: Es incompatible con la vida a largo plazo, ya que el HDL cumple funciones esenciales de transporte de lípidos y protección vascular; tener HDL indetectable o cero absoluto indicaría un trastorno genético gravísimo (como la enfermedad de Tangier, aunque en esos casos raros quedan vestigios mínimos).
• Cifras desorbitadas de LDL (por ejemplo, superiores a 400 o 500 mg/dL) suelen deberse a hipercolesterolemia familiar homocigota o heterogénea, una condición genética seria que requiere tratamiento especializado urgente.
Puedes consultar más detalles oficiales en la guía de MedlinePlus en español.
Si lo deseas, puedes comentarme:
• ¿Tienes a la mano un análisis de sangre reciente con tus valores?
• ¿Tienes antecedentes familiares de problemas del corazón o colesterol alto?
Con esos datos, puedo explicarte de forma más personalizada qué significan tus números.

**Análisis**

Los datos que aporta son correctos dadas las fuentes de las que lo ha sacado. Se confirma que los valores en la base de datos no son tan dispares como para que no se puedan dar en la realidad, salvo el valor negativo, que ya se sabía que era un error, aunque añade también el cero como un error.

**Prompt**

rango de trigliceridos, cuando es preocupante o imposible

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

Los niveles de triglicéridos miden la cantidad de grasa en la sangre. Un nivel superior a 150 mg/dL se considera elevado, y superar los 500 mg/dL es preocupante debido al riesgo inmediato de pancreatitis.
A continuación se detallan los rangos estándar y los niveles críticos:
Rangos de triglicéridos en sangre
Nivel de Triglicéridos Clasificación Significado y Riesgos
Menos de 150 mg/dL Normal Nivel óptimo para la salud cardiovascular.

150 a 199 mg/dL Límite alto Comienza a aumentar el riesgo cardiovascular a largo plazo.
200 a 499 mg/dL Alto Requiere cambios de estilo de vida y posible tratamiento médico.
500 mg/dL o más Muy alto (Preocupante) Riesgo elevado de pancreatitis aguda, una inflamación grave del páncreas.
¿Cuándo es preocupante?
Es preocupante en dos escenarios principales:
• Mayor a 200 mg/dL de forma sostenida: Aumenta notablemente el riesgo de sufrir un infarto, un accidente cerebrovascular (ACV) o desarrollar endurecimiento de las arterias (arteriosclerosis).
• Mayor a 500 mg/dL (Hipertrigliceridemia grave): Es una emergencia médica latente. A este nivel, el riesgo principal ya no es solo el corazón, sino que el páncreas sufra un ataque inflamatorio agudo (pancreatitis), lo cual requiere hospitalización inmediata. En casos extremos, algunas personas pueden registrar valores de 1,000 a 5,000 mg/dL o más.
¿Cuándo es ïmposible¿
En medicina no existe un límite numérico superior ïmposible", pero se consideran valores extraordinarios o errores de laboratorio bajo ciertas condiciones:
• Cifras inhumanas: Valores que superen los 10,000 mg/dL son extremadamente raros y suelen estar vinculados a mutaciones genéticas graves (como el síndrome de quilomicronemia familiar). A ese nivel, la sangre adquiere un aspecto lechoso o cremoso.
• Cero absoluto (0 mg/dL): Es biológicamente imposible tener 0 mg/dL de triglicéridos, ya que el cuerpo los necesita constantemente para almacenar y transportar energía. Un valor extremadamente bajo (por debajo de 30 mg/dL) es muy raro y suele indicar desnutrición severa, malabsorción o una condición genética llamada abetalipoproteinemia.
Si cuentas con un resultado de laboratorio reciente, cuéntame: ¿qué valor exacto obtuviste y si venías guardando un ayuno de 9 a 12 horas? Así podré darte una orientación más precisa.

**Análisis**

Los datos que aporta son correctos dadas las fuentes de las que lo ha sacado. Se confirma que los valores en la base de datos no son tan dispares como para que no se puedan dar en la realidad, salvo el valor negativo, que ya se sabía que era un error, aunque añade también el cero como un error.

**Prompt**

rango glucosa en ayunas, cuando es preocupante o imposible

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

Los niveles de glucosa en sangre en ayunas determinan el estado metabólico de una persona. Un nivel en ayunas entre 70 y 99 mg/dL se considera normal, mientras

que valores persistentemente elevados indican prediabetes o diabetes.

Rangos de glucosa en ayunas

Nivel de glucosa (mg/dL) Clasificación Significado

Menos de 70 mg/dL Hipoglucemia Azúcar bajo en sangre; requiere atención inmediata.

70 a 99 mg/dL Normal Rango óptimo y saludable.

100 a 125 mg/dL Prediabetes Alerta de resistencia a la insulina; requiere cambios de estilo de vida.

126 mg/dL o más Diabetes Criterio de diagnóstico para diabetes (si se repite en dos pruebas distintas).

Cuándo es preocupante

Un valor es preocupante cuando entra en rangos extremos que ponen en riesgo inmediato la salud o indican una patología descontrolada:

- Por debajo de 55 mg/dL (Hipoglucemia severa): Es una urgencia médica inmediata. Puede provocar desmayos, convulsiones, confusión y pérdida del conocimiento.
- Por encima de 250 - 300 mg/dL (Hiperglucemia severa): Es sumamente peligroso, especialmente si se acompaña de síntomas como sed extrema, visión borrosa o náuseas. En personas con diabetes tipo 1 puede desencadenar cetoacidosis diabética, y en tipo 2, un estado hiperosmolar, ambas condiciones potencialmente mortales.

Qué se considera ïmposible.º un error de medición

En la práctica clínica o con el uso de glucómetros caseros, existen valores que son biológicamente incompatibles con la vida si se mantienen, o que sugieren un error del dispositivo:

- 0 mg/dL o valores cercanos a cero: El cerebro consume glucosa constantemente; un valor de cero es biológicamente imposible en una persona viva y consciente. Indica un fallo del glucómetro o una tira reactiva dañada.
- Por encima de 600 - 999 mg/dL: Aunque existen casos extremos de shock hiperosmolar donde se han registrado más de 1000 mg/dL, la mayoría de los glucómetros comerciales están programados para no medir más allá de 500 o 600 mg/dL (mostrando la palabra ”HI.º error). Si sale este valor en una persona sin síntomas graves, suele ser por restos de azúcar o comida en el dedo al pincharse.

Si estás analizando tus propios resultados, ¿has obtenido algún valor específico que te preocupe o estás experimentando algún síntoma como mareos, sed excesiva o cansancio extremo?

**Análisis**

Los datos que aporta son correctos dadas las fuentes de las que lo ha sacado. Se confirma que los valores en la base de datos no son tan dispares como para que no se puedan dar en la realidad.

**Prompt**

rango IMC, cuando es preocupante o imposible

**Respuesta IA** Gemini Flash Lite 3.5 en Gemini

El Índice de Masa Corporal (IMC) es un indicador de la relación entre el peso y la talla. El rango normal de IMC es de 18.5 a 24.9.
A continuación se detallan los rangos oficiales de la Organización Mundial de la Salud (OMS), cuándo empieza a ser preocupante y qué límites se consideran biológicamente imposibles.
Rangos oficiales del IMC (Adultos)
Clasificación Rango de IMC
Bajo peso Menos de 18.5
Peso normal 18.5 – 24.9
Sobrepeso 25.0 – 29.9
Obesidad Clase I (Moderada) 30.0 – 34.9
Obesidad Clase II (Severa) 35.0 – 39.9
Obesidad Clase III (Mórbida) 40.0 o más
Cuándo es preocupante
El IMC se vuelve preocupante cuando se entra en los extremos, ya que aumenta drásticamente el riesgo de mortalidad y enfermedades crónicas:
• Por debajo de 16.0 (Delgadez severa): Es preocupante porque compromete el sistema inmune, causa pérdida de masa ósea, debilidad muscular y puede indicar trastornos de la conducta alimentaria (como la anorexia) o enfermedades subyacentes graves.
• Por encima de 35.0 (Obesidad severa y mórbida): Es preocupante debido al alto riesgo de sufrir eventos cardiovasculares (infartos, hipertensión), diabetes tipo 2, apnea del sueño, problemas articulares severos y ciertos tipos de cáncer.
Cuándo es ïmposible.º un error de cálculo
Dado que el IMC es una fórmula matemática (Peso en kg / Estatura en metros$^2$), se pueden introducir números que den cualquier resultado, pero biológicamente existen límites para la supervivencia humana:
• IMC menor a 10-12: Es prácticamente imposible sobrevivir en este rango. Un IMC tan bajo significa que el cuerpo ha consumido casi todo su tejido graso y muscular, lo que provoca un fallo multiorgánico fatal.
• IMC mayor a 100-120: Aunque se han registrado casos excepcionales en la historia de la medicina de personas con obesidad extrema que han alcanzado un IMC cercano a 100 o poco más (pesando más de 400-500 kg), un valor significativamente superior a este rango suele deberse a un error al introducir los datos en la calculadora.
Limitación importante del IMC
El IMC no distingue entre grasa y músculo. Una persona muy musculosa (como un culturista) puede tener un IMC superior a 30 (clasificado como .ºbesidad") sin tener un exceso de grasa corporal. Por ello, los profesionales de la salud suelen complementarlo con la medición del perímetro de la cintura o el porcentaje de grasa corporal.
Si lo deseas, puedo ayudarte a calcular un caso específico si me proporcionas:
• El peso (en kilogramos o libras)
• La estatura (en centímetros o pies/pulgadas)
• Si es para un adulto o un menor de edad (ya que en niños se usan percentiles)

**Análisis**

Los datos que aporta son correctos dadas las fuentes de las que lo ha sacado. El límite máximo de la muestra (50.60) se encuentra dentro de los márgenes biológicos de la obesidad mórbida. Sin embargo, el límite inferior de la muestra presenta un valor mínimo de 3.6 de IMC, el cual está significativamente por debajo del límite sugerido por la IA (12-13). Asimismo, se evalúa la recomendación de la IA basada en los criterios de la OMS para discretizar la variable IMC en clases, cuya viabilidad se determinará según cuánto beneficie al modelo escogido.

**Prompt**

la presión sistólica debe de ser mayor que la presión diastólica siempre?

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

Sí, la presión sistólica (el número superior) siempre debe ser mayor que la presión diastólica (el número inferior) en condiciones normales.

- Presión sistólica: Mide la fuerza de la sangre contra las paredes de las arterias cuando el corazón se contrae (late) para bombear sangre. Como el corazón está haciendo su máximo esfuerzo de expulsión, esta cifra siempre es más alta (lo normal es menor de 120 mmHg).
- Presión diastólica: Mide la presión que queda en las arterias cuando el corazón se relaja entre un latido y otro para llenarse de sangre. Esta cifra siempre es menor (lo normal es menos de 80 mmHg).

¿Qué pasa si las presiones "se juntan.º se invierten?

- Diferencia muy pequeña (presiones juntas): Si la diferencia entre la sistólica y la diastólica es muy reducida (por ejemplo, 120/100 mmHg), indica un problema médico que requiere evaluación, ya que la sangre no fluye con la diferencia de presión adecuada entre la contracción y el reposo del corazón.
- Presión invertida (diastólica mayor que la sistólica): En la práctica clínica normal no es posible que la diastólica supere a la sistólica; si un monitor de presión arterial muestra un valor así, suele deberse a un error de medición (como un brazalete mal colocado, movimiento o un fallo en el aparato) y se debe repetir la toma en reposo. Si los síntomas persisten o te sientes mal, consulta a un profesional de la salud. Puedes revisar más detalles sobre las lecturas en la guía de MedlinePlus.

Si lo deseas, dime:

- ¿Qué valores específicos estás observando o te preocupa interpretar?
- ¿Se trata de una medición aislada o te han diagnosticado hipertensión?

**Análisis**

En el último prompt de Google AI Studio que comentaba varios errores a corregir o eliminar, sugiría comprobar que la presión diastólica no fuese mayor que la sistólica. Con esta consulta, y comprobando las fuentes, se confirma explícitamente que en la práctica clínica normal no es posible que se supere y que por tanto suele deberse a un error de medición.

**Prompt**

rango frecuencia cardiaca en reposo, cuando es preocupante o imposible

**Respuesta IA** Gemini Flash Lite 3.5 en Gemini

El rango normal de la frecuencia cardíaca en reposo (FCR) para adultos es de 60 a 100 latidos por minuto (lpm).
Rangos de la Frecuencia Cardíaca en Reposo
Frecuencia (lpm) Estado Qué significa
Menos de 60 Bradycardia (Baja) Normal en atletas bien entrenados o durante el sueño profundo.
60 a 100 Normal El corazón bombea de manera eficiente en un adulto promedio en reposo.
Más de 100 Taquicardia (Alta) El corazón late demasiado rápido. Puede deberse a estrés, fiebre, deshidratación o problemas de salud.
Cuándo es preocupante
Debes prestar atención o consultar a un médico en las siguientes situaciones:
• Frecuencia en reposo constantemente >100 lpm: Puede indicar problemas tiroideos, anemia o arritmias.
• Frecuencia en reposo <50-60 lpm (si no eres atleta): Especialmente si te sientes débil.
• Acompañada de síntomas: Cualquier número fuera de rango es alarmante si va junto con:
• Mareos o vértigo
• Dificultad para respirar
• Dolor o presión en el pecho
• Desmayos o síncope
Cuándo es ïmposible"(Incompatible con la vida)
Bajo condiciones normales de reposo absoluto y sin soporte médico artificial, existen límites biológicos extremos:
• 0 lpm (Asistolia): El corazón se detiene por completo. El cerebro sufre daños irreversibles en 4-6 minutos sin reanimación (RCP).
• Menos de 20-30 lpm: Un corazón humano difícilmente puede mantener el conocimiento o la vida a este ritmo de forma prolongada sin un marcapasos artificial, ya que el cerebro no recibe suficiente oxígeno.
• Más de 220-250 lpm en reposo absoluto: Frecuencias tan extremadamente altas impiden que las cámaras del corazón se llenen de sangre entre latidos. Esto provoca un colapso circulatorio inmediato (frecuente en la fibrilación ventricular), lo que equivale a un paro cardíaco.
Para darte una respuesta más precisa, ¿podrías decirme si estás midiendo tus propios latidos, qué número exacto obtuviste y si sientes algún síntoma como mareos o fatiga?

**Análisis**

Los datos que aporta son correctos dadas las fuentes de las que lo ha sacado. Se confirma que el límite superior (112.70) es un valor clínicamente viable, pero no

queda claro si el límite inferior (25.80), que está en el rango de los 20-30 lmp, es simplemente un valor crítico o si no se puede dar en la realidad.

**Prompt**

entonces, un valor entre 20-30 lpm es un valor que se le podría registrar a un paciente o es un error?

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

Un valor entre 20 y 30 lpm sí se le puede registrar a un paciente real, pero representa una bradicardia extrema y una emergencia médica absoluta. No debe asumirse automáticamente que es un error de medición, aunque siempre debe confirmarse de inmediato con un electrocardiograma (ECG) clínico o la toma manual del pulso periférico y central.

En la práctica clínica, cuando un monitor o dispositivo registra esta cifra, se consideran dos escenarios principales:

1. Es una condición médica real (Patológica u Fisiológica Extrema)

Si la lectura es real, el paciente se encuentra en una situación crítica en la que su cerebro y órganos no están recibiendo suficiente oxígeno:

• Bloqueos cardíacos graves o enfermedad del nodo sinusal: El sistema eléctrico del corazón está fallando. En un bloqueo auriculoventriculo (AV) completo de tercer grado, las aurículas y los ventrículos se desconectan y el corazón activa un ritmo de escape"ventricular que late de forma natural a solo 20-40 lpm para mantener al paciente con vida temporalmente.

• Intoxicaciones por medicamentos: Sobredosis accidentales de fármacos como los betabloqueantes o la digoxina pueden deprimir el ritmo cardíaco hasta estos niveles.

• Límite humano fisiológico (Casos excepcionales): A nivel mundial, se han documentado de forma oficial casos aislados de atletas de élite en disciplinas de resistencia extrema (como el ciclista Miguel Induráin con 28 lpm) o variantes genéticas saludables excepcionales donde el pulso en reposo profundo ha llegado a 26-27 lpm sin síntomas de enfermedad. Sin embargo, esto ocurre en menos del 0.4 % de la población mundial y nunca en una persona sedentaria o enferma.

2. Es un error técnico del dispositivo (Artefacto)

En entornos domésticos con relojes inteligentes o pulsómetros de dedo (oxímetros), un registro de 20-30 lpm a menudo es un error de lectura provocado por:

• Mala perfusión sanguínea (manos frías): Si el paciente tiene los dedos helados o hipotensión, el sensor óptico no detecta bien el pulso y puede "saltarse"latidos reales, dividiendo la cifra real a la mitad (ej. registrar 25 lpm cuando el pulso real es de 50 lpm).

• Movimiento o sudor: El desplazamiento del sensor confunde al software del dispositivo.

• Arritmias específicas (Bigeminismo): Si el corazón late con un patrón de "latido fuerte - latido débil muy pegado", el monitor electrónico puede contar únicamente los latidos fuertes, mostrando la mitad de la frecuencia real en la pantalla.

¿Qué hacer ante un registro de 20-30 lpm?

La regla médica de oro es evaluar al paciente, no a la máquina:

1. Comprobar los síntomas: Si el paciente presenta desmayos (síncopes), mareos intensos, piel pálida/fría, confusión o falta de aire, la lectura es altamente compatible con una crisis real y requiere llamar a emergencias de inmediato. Generalmente, estas situaciones se solucionan en el hospital mediante medicación intravenosa de urgencia o la implantación de un marcapasos definitivo.
2. Confirmación manual: Palpar directamente el pulso carotídeo (en el cuello) durante un minuto completo para verificar si coincide con los latidos del monitor.
Si estás viendo esta medición en este momento, infórmame:
- ¿El paciente presenta mareos, desmayos, palidez o dificultad para respirar?
- ¿La medición proviene de un reloj/oxímetro de casa o de un monitor de hospital?
- ¿Se ha intentado tomar el pulso de forma manual en el cuello o la muñeca?

**Análisis**

Con esta consulta se confirma que el límite inferior se trata de un valor crítico en un paciente y no de un error.

**Prompt**

rango proteína c reactiva, cuando es preocupante o imposible

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

La proteína C reactiva (PCR) es una proteína producida por el hígado que aumenta en la sangre cuando hay inflamación o infección en el cuerpo.
El rango normal general de la PCR en adultos es menor a 8 o 10 mg/L (o menos de 0.8 a 1.0 mg/dL, dependiendo del laboratorio).
A continuación se detalla cuándo los niveles empiezan a ser preocupantes y qué valores se consideran biológicamente imposibles.
Niveles de PCR y su significado clínico
Nivel de PCR Interpretación Causas comunes
Menor a 10 mg/L Normal Estado saludable o inflamación insignificante.
10 a 50 mg/L Elevación leve a moderada Infecciones locales (bronquitis, cistitis), traumatismos menores, tabaquismo, obesidad, embarazo o estrés severo.
50 a 100 mg/L Elevación moderada a alta Infecciones bacterianas sistémicas, brotes de enfermedades autoinmunes (artritis reumatoide, lupus) o infarto de miocardio reciente.
Mayor a 100 mg/L Elevación muy alta Infecciones bacterianas graves (sepsis), quemaduras extensas, traumatismos mayores o vasculitis sistémicas.
¿Cuándo es preocupante?
Un nivel de PCR se vuelve preocupante bajo los siguientes criterios: • Mayor a 50 mg/L: Sugiere un proceso inflamatorio activo que requiere evaluación médica para identificar la causa (usualmente una infección bacteriana o un brote autoinmune).
• Mayor a 100 mg/L: Es un criterio de alarma médica inmediata. Suele indicar infecciones bacterianas agudas y potencialmente mortales como la sepsis o una neumonía grave.
• Elevación crónica menor (PCR ultrasensible): Si se mide con la prueba de

PCR ultrasensible (PCR-us) y se mantiene entre 1 y 3 mg/L o más, no indica una emergencia médica, pero sí un riesgo elevado de padecer enfermedades cardiovasculares (infartos o accidentes cerebrovasculares) a largo plazo.

¿Cuándo es imposible o un error de laboratorio?

En la biología humana existen límites físicos para la producción de esta proteína:

- Valores superiores a 500 - 600 mg/L: Son extremadamente raros, aunque pueden verse de forma excepcional en casos críticos de sepsis grave o shock séptico masivo.
- Valores superiores a 1000 mg/L: Se consideran prácticamente imposibles en un contexto clínico real. Si un reporte de laboratorio indica una cifra cercana o superior a los 1000 mg/L, lo más probable es que se trate de un error de transcripción, un fallo de calibración del analizador o una interferencia analítica (como la presencia de anticuerpos heterófilos o factor reumatoide en la muestra que alteran la medición).

En este escenario, la conducta estándar es repetir la toma de muestra de inmediato. Si tienes un resultado de PCR en la mano y deseas interpretarlo con mayor precisión, puedes compartirme el valor exacto, las unidades del laboratorio (mg/L o mg/dL) y si presentas síntomas como fiebre, dolor o fatiga.

**Análisis**

Al leer la consulta, volvió a aparecer el concepto de PCR ultrasensible para enfermedades cardiovasculares, el cual había salido también en el último prompt de Google AI Studio. Tras regresar al enunciado de la práctica, se confirmó que el atributo correspondía a la variante ultrasensible, por lo que se descartan los límites dados en esta consulta.

**Prompt**

rango proteína c reactiva ultrasensible para detección de riesgo cardiovascular, cuando es preocupante o imposible

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

La proteína C reactiva ultrasensible (PCR-us o hs-CRP) mide niveles mínimos de inflamación sistémica en la sangre para evaluar el riesgo de enfermedades cardiovasculares (como infartos o accidentes cerebrovasculares).

Rangos de riesgo cardiovascular (en mg/L)

- Menos de 1 mg/L: Riesgo cardiovascular bajo (perfil inflamatorio controlado).
- 1 a 3 mg/L: Riesgo cardiovascular moderado o intermedio (zona gris o de atención en hábitos de vida).
- Más de 3 mg/L: Riesgo cardiovascular alto (alerta de inflamación crónica o actividad en los vasos sanguíneos).

¿Cuándo es preocupante?

- Un valor superior a 3 mg/L indica un mayor riesgo de eventos coronarios y requiere revisar factores como tabaquismo, sedentarismo, resistencia a la insulina o el perfil lipídico.
- Si el resultado es mayor a 10 mg/L, no suele reflejar riesgo cardiovascular crónico, sino un proceso agudo en curso (como una infección bacteriana o viral,

un traumatismo, una lesión reciente o un brote inflamatorio/reumatológico).
• Qué hacer: En estos casos de valores >10 mg/L, los médicos generalmente recomiendan repetir la prueba tras 2 o 3 semanas (cuando la persona se haya recuperado) para saber si el valor alto era transitorio o si persiste una inflamación de fondo.
¿Cuándo puede dar un resultado alterado o ïmposible"de interpretar de forma directa?
Existen situaciones clínicas y fisiológicas que elevan la PCR-us sin que exista una enfermedad cardiaca primaria, lo cual debe ser tenido en cuenta por el médico:
• Infecciones agudas o recientes (resfriados, gripe, infecciones urinarias, etc.).
• Embarazo (los niveles aumentan de forma natural).
• Uso de estrógenos o anticonceptivos orales.
• Enfermedades inflamatorias crónicas o autoinmunes (artritis reumatoide, lupus), donde la inflamación articular eleva el marcador por motivos ajenos al riesgo vascular directo.
• Traumatismos recientes, cirugías o ejercicio físico muy intenso realizado justo antes de la extracción.
Si lo deseas, puedes comentarme:
• Cuál fue el valor exacto que obtuviste (y si estaba en mg/L o mg/dL).
• Si tenías algún síntoma, infección reciente o tomas medicación.
Así podremos revisar qué contexto médico podría estar influyendo en ese resultado.

**Análisis**

La IA sugiere descartar los valores que superen los 10 mg/L porque no suele reflejar riesgo cardiovascular crónico y los médicos generalmente suelen recomendar repetir la prueba a las 2-3 semanas. Este mismo límite aparecía también en la última consulta de Google AI Studio. Al consultar las fuentes, se confirma que este umbral realmente se aplica en medicina, por lo que se acepta la sugerencia de la IA.

**Prompt**

rango nivel sérico de ácido úrico, cuando es preocupante o imposible

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

El ácido úrico es un producto de desecho que se forma cuando el cuerpo descompone unas sustancias llamadas purinas. Los niveles en sangre se miden habitualmente mediante un análisis de sangre básico.
A continuación, te detallo los rangos de referencia generales, cuándo se consideran preocupantes y qué significan cifras extremas o «imposibles» de interpretar clínicamente.
—
1. Rangos normales de nivel sérico de ácido úrico
Los valores de referencia estándar en laboratorios suelen ser:
* **Hombres:** Entre **3.4 y 7.0 mg/dL** (miligramos por decilitro).
* **Mujeres:** Entre **2.4 y 6.0 mg/dL** (los valores suelen ser ligeramente más

bajos antes de la menopausia).
* *Nota:* Los rangos exactos pueden variar ligeramente según el laboratorio o el equipo de medición utilizado.

—

2. ¿Cuándo es preocupante? (Hiperuricemia)
Se habla de **hiperuricemia** cuando los niveles superan los límites superiores mencionados (más de 6.0 mg/dL en mujeres o más de 7.0 mg/dL en hombres). Sin embargo, un nivel elevado no siempre causa síntomas inmediatos. Se vuelve preocupante o requiere atención médica en los siguientes escenarios:
* **Riesgo de Gota:** Cuando el ácido úrico se eleva de forma sostenida, puede cristalizar en las articulaciones, provocando ataques de gota (artritis inflamatoria muy dolorosa, comúnmente en el dedo gordo del pie).
* **Formación de Piedras en el Riñón (Nefrolitiasis):** Los niveles altos aumentan la probabilidad de desarrollar cálculos renales, lo que causa cólicos renales intensos y dolor en la espalda baja o el flanco.
* **Daño Renal o Metabólico:** Niveles muy altos de manera crónica pueden asociarse con problemas renales, hipertensión, resistencia a la insulina o síndrome metabólico.
* *Asintomático:* Si un análisis muestra valores ligeramente altos pero nunca has tenido síntomas ni antecedentes de gota, por lo general no se medica de inmediato, aunque sí se aconsejan cambios en el estilo de vida (dieta, hidratación, control de peso).

—

3. Valores «imposibles» o clínicamente incoherentes
Desde una perspectiva médica y fisiológica, existen situaciones donde un valor de ácido úrico carece de sentido o es técnicamente imposible en sangre:
* **Valores negativos:** El ácido úrico no puede ser un número negativo ($<$ 0 mg/dL).
* **Valores absurdamente altos sin clínica extrema (Errores de laboratorio o transcripción):** Cifras extremadamente elevadas (por ejemplo, 30, 50 o 100 mg/dL) en una persona que camina por la calle sin estar hospitalizada suelen deberse a un error de transcripción, una interferencia en la muestra de sangre o una mala toma de la muestra.
* **El límite biológico en humanos:** En pacientes con insuficiencia renal severa o en procesos agudos de destrucción celular masiva (como durante la quimioterapia por ciertos cánceres, conocido como *síndrome de lisis tumoral*), los valores pueden subir drásticamente, pero cifras superiores a 15-20 mg/dL de forma aislada sin una enfermedad crítica subyacente grave son extremadamente raras y suelen requerir revisión urgente.
¿Te gustaría saber qué alimentos o hábitos ayudan a mantener el ácido úrico en niveles saludables?

**Análisis**

Los datos que aporta son correctos dadas las fuentes de las que lo ha sacado. Se confirma que los valores en la base de datos no son tan dispares como para que no se puedan dar en la realidad.

**Prompt**

rango tasa de filtrado glomerular / depuración de creatinina, cuando es preocupante o imposible

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

La evaluación de la función renal se realiza principalmente a través de la Tasa de Filtrado Glomerular (TFG o GFR) o mediante la Prueba de Aclaramiento/Depuración de Creatinina (que estima dicho filtrado a través de muestras de sangre y orina de 24 horas). Ambos valores indican cuántos mililitros de sangre purifican los riñones por minuto.
Los rangos de referencia, las cifras de alarma y los límites biológicos se clasifican de la siguiente manera:
1. Rangos normales y de referencia
• TFG / Aclaramiento Normal: 90 mL/min/1.73 $m^2$ o superior se considera el estado óptimo y saludable.
• Disminución leve: Entre 60 y 89 mL/min. En muchos casos (como en adultos mayores) puede ser un declive fisiológico normal por la edad o una señal temprana si existen factores como diabetes, hipertensión o proteínas en la orina (albuminuria).
2. Cuándo es preocupante (Criterios Médicos)
Un descenso en estos valores empieza a ser clínicamente relevante bajo dos escenarios:
• Preocupante / Sospecha de Enfermedad Renal Crónica (menor a 60 mL/min): Un valor de filtrado de entre 30 y 59 mL/min que persiste durante 3 o más meses es el criterio clínico universal para diagnosticar Enfermedad Renal Crónica (ERC). Requiere seguimiento por medicina interna o nefrología para frenar la progresión del daño.
• Crítico / Emergencia Médica (menor a 15 mL/min): Cualquier resultado por debajo de 15 mL/min representa una insuficiencia renal terminal (Fallo renal Estadio 5). A estos niveles, los riñones han perdido casi toda su capacidad funcional, acumulando toxinas peligrosas en el cuerpo. Requiere atención médica inmediata y suele hacer necesaria la terapia de reemplazo renal (diálisis o trasplante de riñón).
3. Cuándo un valor es ïmposible.º biológicamente incompatible con la vida
• Filtrado Glomerular de 0 mL/min: Fisiológicamente, un filtrado de cero significa el cese total de la función renal. No se puede sobrevivir de forma prolongada con un filtrado cercano a cero sin soporte artificial (diálisis), ya que la acumulación extrema de potasio, fluidos y desechos metabólicos (uremia) provocaría fallos cardíacos y sistémicos fatales en pocos días.
• Valores artificialmente sobreestimados o errores de laboratorio: En el otro extremo, valores exageradamente altos (por ejemplo, superiores a 150-180 mL/min en adultos que no están embarazadas o en fases iniciales muy específicas de nefropatía diabética) suelen ser fisiológicamente imposibles. Generalmente se deben a errores en la recolección exacta de la orina de 24 horas (recoger menos volumen o calcular mal el tiempo) o a una masa muscular extremadamente baja que altera las fórmulas basadas en la creatinina sérica.
Nota: Un resultado alterado de forma aislada no define una enfermedad crónica. La deshidratación severa, el uso de ciertos medicamentos (como antiinflamatorios) o

el ejercicio extenuante pueden bajar el filtrado o subir la creatinina temporalmente. Siempre se deben repetir las pruebas para confirmar tendencias.
Para ayudarte a interpretar mejor la situación, ¿podrías indicarme:
• ¿Cuál fue el resultado exacto de la TFG o aclaramiento en los análisis?
• ¿Aparece también el valor de la creatinina en sangre y la presencia de proteínas/albúmina en la orina?
• ¿El paciente padece de condiciones crónicas como diabetes o hipertensión?

**Análisis**

Los datos que aporta son correctos dadas las fuentes de las que lo ha sacado. Se confirma que los valores en la base de datos no son tan dispares como para que no se puedan dar en la realidad.

**Prompt**

rango del porcentaje de hemoglobina glicosilada HbA1c en sangre, cuando es preocupante o imposible

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

El porcentaje de hemoglobina glicosilada (HbA1c) mide el nivel promedio de azúcar en la sangre durante los últimos 2 a 3 meses.
El rango normal de HbA1c en adultos sanos es inferior al 5.7 %, mientras que un valor a partir del 6.5 % confirma el diagnóstico de diabetes.
Rangos estándar de HbA1c
• Normal: Menos de 5.7 %
• Prediabetes: 5.7 % a 6.4 %
• Diabetes: 6.5 % o más
¿Cuándo es preocupante?
Un nivel de HbA1c es preocupante tanto por ser demasiado alto como por ser críticamente bajo:
• Preocupante por niveles altos ( 8.0 % o más): Si una persona con diabetes supera el 8.0 %, indica un control deficiente de la glucemia. Valores por encima del 10 % al 12 % son críticamente altos y elevan de forma drástica el riesgo de complicaciones agudas (como cetoacidosis diabética o síndrome hiperosmolar) y daños a largo plazo en ojos, riñones, nervios y corazón.
• Preocupante por niveles bajos (<4.0 %): Un valor extremadamente bajo suele ser peligroso en pacientes medicados para la diabetes, ya que indica episodios frecuentes y graves de hipoglucemia (azúcar en sangre peligrosamente bajo), lo que puede provocar desmayos, convulsiones o coma.
¿Cuándo es biológicamente ïmposible¿
En la práctica médica, existen límites físicos y biológicos para este porcentaje: • Límite superior (Imposible >20 % - 25 %): Es prácticamente imposible ver valores superiores al 20 % o 25 %. Para alcanzar un 20 %, el azúcar en sangre promedio tendría que superar de forma sostenida los 500-600 mg/dL durante meses, lo cual es incompatible con la vida a mediano plazo debido a la toxicidad y la deshidratación extrema.

• Límite inferior (Imposible <2.5 % - 3.0 %): Los glóbulos rojos siempre están expuestos a algo de glucosa en el cuerpo humano vivo. Un porcentaje inferior al 3.0 % es biológicamente incompatible con la supervivencia, salvo en casos de errores de laboratorio o variantes genéticas extremas de la hemoglobina.

**Análisis**

Para el límite superior no habría problema, pero el límite inferior sería imposible que se presentase clínicamente según los valores de la consulta. Sin embargo, no hay fuentes proporcionadas para contrastar la información, por lo que aún no se acepta.

**Prompt**

proporcióname fuentes para verificar el límite inferior

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

El fundamento biológico de por qué la hemoglobina glicosilada (HbA1c) tiene un límite inferior biológico e imposible de cruzar (en torno al 2.5 % - 3.0 %) en un ser humano vivo se sustenta en consensos clínicos, guías metabólicas y estudios hematológicos.
Las principales bases científicas y los mecanismos médicos que explican este límite son los siguientes:
1. El proceso de glicación no enzimática (Efecto químico inevitable)
La HbA1c no se produce por una orden del organismo, sino por una reacción química pasiva y lenta llamada reacción de Maillard. La glucosa presente en el plasma se adhiere de forma permanente a la hemoglobina de los glóbulos rojos durante sus aproximadamente 120 días de vida útil. Como el cerebro y otros órganos vitales necesitan un mínimo de glucosa constante en sangre para no sufrir muerte cerebral (incluso en estados de ayuno extremo o desnutrición), siempre hay azúcar en el torrente sanguíneo. Al haber glucosa circulante y glóbulos rojos conviviendo en el mismo espacio, es químicamente imposible que la tasa de glicación caiga a cero.
2. Guías Clínicas de la ADA (American Diabetes Association)
En los estándares de atención médica de la American Diabetes Association (ADA), se describe que el percentil más bajo observado en poblaciones humanas sanas sin patologías hematológicas se sitúa alrededor del 4.0 % al 4.5 %. Los laboratorios clínicos calibrados bajo el Programa Nacional de Estandarización de Glicohemoglobinas (NGSP) configuran sus rangos de referencia con este suelo protector. Cualquier valor que comience a bajar del 4.0 % enciende alertas automáticas de hipoglucemia severa o de anomalías en la muestra.
3. Falsos Negativos e Ïmposibles"por Interferencias Hematológicas
Cuando un laboratorio registra un valor extraordinariamente bajo (cercano o inferior al 3.0 %), la literatura médica indica que casi nunca se debe a un nivel real de azúcar, sino a alteraciones en la vida del glóbulo rojo o a variantes genéticas. Las principales referencias sobre estas interferencias analizan los siguientes fenómenos:
• Acortamiento de la vida útil del eritrocito: Publicaciones indexadas en PubMed Central (PMC) detallan que condiciones como la anemia hemolítica aguda o las

transfusiones de sangre recientes provocan que los glóbulos rojos se destruyan mucho antes de los 120 días o se reemplacen por células nuevas sin glicar. Al no darles tiempo físico de entrar en contacto con el azúcar, el valor de HbA1c cae artificialmente, simulando un límite biológico alterado.

• Deficiencia de G6PD y Hemoglobinopatías: Un estudio publicado en la revista científica Diabetes Care evidenció cómo ciertas condiciones genéticas silenciosas (como la deficiencia de la enzima glucosa-6-fosfato deshidrogenasa o variantes de la hemoglobina como la HbS o HbC) arrojan valores de HbA1c falsamente bajos e inexactos debido a métodos de medición interferidos o a una menor supervivencia celular, a pesar de que el paciente presente glucemias normales o incluso elevadas.

• Errores metodológicos en Laboratorio: Revistas especializadas como JAMA señalan que la presencia de hemoglobinas anormales interfiere físicamente con tecnologías estándar como la Cromatografía Líquida de Alta Resolución (HPLC). El equipo confunde las variantes proteicas y reporta lecturas erróneas o ïmposibles"que requieren métodos alternativos de control (como la medición de fructosamina).

En resumen, un valor inferior al 3 % es catalogado en medicina como un artefacto técnico (error de medición) o una emergencia biológica incompatible con la homeostasis humana general.

## Análisis

Ahora que se han podido consultar las fuentes, se acepta la decisión de considerar un valor inferior al 3 % como error para la hemoglobina glicosilada.

## Prompt

```
# E. Incoherencia de lípidos: Colesterol total menor que la suma de sus fracciones (HDL + LDL)
inval_lipidos = (
    df["colesterol_total"] < (df["colesterol_hdl"] + df["colesterol_ldl"])
).sum()
incoherencias_clinicas["Colesterol Total < (HDL + LDL)"] = inval_lipidos
```

Esta comprobacion esta mal, no deberíamos comprobar si se cumple la fórmula?

## Respuesta IA — Gemini Flash 3.8 en Google AI Studio

Tienes razón en tu intuición de que la fórmula completa debe considerarse, pero
la comprobación que tienes escrita no está conceptualmente mal, sino que es una
comprobación de mínimos absolutos.

Sin embargo, no es suficiente y tiene matices importantes de laboratorio que
debes conocer para no descartar datos válidos.

Aquí te explico por qué tu comprobación actual sirve como filtro de corte, por
qué validar la fórmula exacta puede ser un error, y cuál es la forma correcta de

```
programarlo.

1. ¿Por qué la comprobación que tienes es válida (como cota mínima)?

El colesterol total se compone de tres fracciones principales:
\text{Colesterol Total} = \text{HDL} + \text{LDL} + \text{VLDL}

Dado que el colesterol VLDL (asociado a los triglicéridos) nunca puede
ser
negativo (\text{VLDL} > 0), matemáticamente se cumple siempre que:
\text{Colesterol Total} > \text{HDL} + \text{LDL}

Por tanto, si en tus datos: colesterol_total < (colesterol_hdl +
colesterol_ldl)

Significa que el todo es menor que la suma de solo dos de sus partes.
Esto es
una imposibilidad matemática y biológica directa. Si esto ocurre, hay un
error
seguro de digitación. Por eso tu código actual es un excelente detector
de
fallos graves.

2. ¿Por qué NO deberías exigir que la fórmula se cumpla de forma exacta?

Podrías tener la tentación de comprobar la Fórmula de Friedewald:
\text{Colesterol Total} \approx \text{HDL} + \text{LDL} +
\frac{\text{Triglicéridos}}{5}

Exigir que esta igualdad se cumpla al 100% en tu dataset te dará falsos
positivos de error (creerás que los datos están mal cuando en realidad
son
correctos) por dos motivos:

1.  Método de medición directa de LDL: Hoy en día, muchos laboratorios ya
no
    estiman el LDL con la fórmula matemática, sino que lo miden
    directamente en
    sangre mediante reactivos químicos (Direct LDL assay). Las mediciones
    directas tienen márgenes de error analítico (\pm 3-5\%) que hacen que
    la
    suma nunca cuadre al milímetro.
2.  Fallo de la fórmula con triglicéridos altos: La aproximación
    \text{VLDL} \approx \text{Triglicéridos} / 5 deja de ser válida si
    los
    triglicéridos son > 400\text{ mg/dL}, y falla bastante si son
    > 200\text{ mg/dL} o < 50\text{ mg/dL}.

3. La forma correcta y robusta de comprobarlo en Python
```

```
Lo ideal es permitir una pequeña tolerancia fisiológica/analítica
(alrededor de
un 5% a 10%) para no penalizar el redondeo del laboratorio, pero marcar
aquellos
casos donde la discrepancia sea un disparate.

Aquí tienes cómo estructurar esta validación de forma profesional:

# 1. Error Grave e Imposible: El Total es significativamente menor que
HDL + LDL
# Dejamos un margen de tolerancia del 5% por variabilidad analítica del
laboratorio
tolerancia = 0.95
error_suma_basica = (
    df["colesterol_total"] < (df["colesterol_hdl"] +
    df["colesterol_ldl"]) * tolerancia
).sum()

# 2. Comprobación de la Fórmula de Friedewald (solo válida si
Triglicéridos < 400)
# Estimamos el colesterol esperado según la fisiología clásica
colesterol_esperado = (
    df["colesterol_hdl"] + df["colesterol_ldl"] + (df["trigliceridos"] /
    5)
)

# Calculamos la discrepancia porcentual respecto al total registrado
diferencia_relativa = (
    abs(df["colesterol_total"] - colesterol_esperado) /
    df["colesterol_total"]
)

# Filtramos: Solo evaluamos donde Triglicéridos < 400 y la diferencia sea
> 15% (muy grande)
error_friedewald = (
    (df["trigliceridos"] < 400) & (diferencia_relativa > 0.15)
).sum()

# Guardamos los resultados
incoherencias_clinicas["Error Crítico: Total < (HDL + LDL)"] =
error_suma_basica
incoherencias_clinicas["Discrepancia severa en perfil lipídico (>15%)"] =
(
    error_friedewald
)

Resumen para tu pipeline:

  - Conserva tu comprobación original (con o sin el pequeño margen del
  5%): si
```

```
  Total < HDL + LDL, el dato está irremediablemente corrupto.
- Si quieres ir más allá y verificar la fórmula de Friedewald completa,
hazlo
  siempre excluyendo a pacientes con triglicéridos \ge 400\text{ mg/dL}
  y
  permitiendo un margen de error del 10% al 15%.
```

**Análisis**

Se acepta la respuesta de la IA de que la comprobación que hacía mi compañero para detectar valores no válidos para el colesterol total es correcto, cuando se pretendía cambiar esta línea por la fórmula que relacionan los triglicéridos con los dos tipos de colesterol para obtener el colesterol total. También sugiere que a la hora de comprobar los valores esperados con la fórmula, se use un margen de error. Se acepta la sugerencia.

**Prompt**

Me ha salido un 24.8 % de casos en los que no se cumple la fórmula de total <(DDL + LDL) y un 57.76 % de los valores, con un margen del 15 %, me salen que tienen discrepancia. Además, apenas hay correlación del colesterol total con los triglicéridos y con los dos tipos de colesterol y solo hay un 0.10 de correlación con el target. Crees que esta columna podría eliminarse o no?

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

```
Con esos datos en la mano, la respuesta corta es: Sí, eliminar
colesterol_total
es la decisión más sensata y técnicamente defendible.

De hecho, los números que acabas de obtener revelan una realidad muy
común en
ciencia de datos aplicada a la salud: tu columna de colesterol_total está
corrupta o el dataset es sintético y fue mal generado.

Aquí te explico los motivos analíticos, clínicos y de modelado que
justifican su
eliminación:

1. Diagnóstico del problema: Datos rotos o sintéticos

  - Un 24.8% de imposibilidad biológica: Que un cuarto de tu base de
  datos viole
    una ley física básica (Total < HDL + LDL) no es un "margen de error
    de
    laboratorio" (que suele rondar el 2-3%). Es un error sistemático
    masivo.
  - Falta de correlación interna: En biología real, la correlación entre
  el
```

```
    Colesterol Total y el LDL suele ser altísima (r \approx 0.80 - 0.90).
    Si en
    tu dataset no correlacionan entre sí, significa que las variables se
    generaron de forma independiente (ruido aleatorio) o que las columnas
    se
    desalinearon al importar los datos.
  - Un modelo no puede extraer conocimiento médico de una variable cuyos
  valores
    no respetan la estructura subyacente del dominio.

2. Justificación clínica: El Colesterol Total ya es obsoleto por sí solo

Incluso en la medicina real moderna (guías europeas ESC/EAS o americanas
AHA/ACC), el colesterol total apenas se usa de forma aislada para estimar
riesgo
porque es una métrica "ciega":

  - Un paciente puede tener un colesterol total alto (240\text{ mg/dL})
  porque
    tiene un HDL ("bueno") altísimo (90\text{ mg/dL}), lo cual es
    protector.
  - Otro puede tener el mismo total (240\text{ mg/dL}) a expensas de un
  LDL
    ("malo") de 180\text{ mg/dL}, lo cual es peligroso.

Los verdaderos inductores de placa aterogénica y riesgo cardiovascular
son el
LDL, los Triglicéridos y la falta de HDL. Esas tres variables ya las
tienes en
el dataset de forma individual. Mantener un "Total" inconsistente solo
aporta
ruido y confusión (colinealidad rota).

3. Justificación de Machine Learning

  - Correlación de 0.10 con el target: Tiene una capacidad predictiva
    prácticamente nula (linealmente hablando).
  - Sobreasociación espuria: Si dejas la columna, algoritmos basados en
  árboles
    (XGBoost, Random Forest) podrían encontrar "reglas tontas" basadas en
    el
    ruido de esa columna corrupta (overfitting), restando peso a
    variables que
    sí son clínicamente causales como la glucosa, la tensión arterial o
    el LDL.
```

**Análisis**

Mi intención al consultarte sobre las inconsistencias y la baja correlación del colesterol total era validar si esos datos anómalos justificaban descartar la variable

sin perder información clave para el modelo y así tener una primera opinión. Aunque tomo en cuenta sus argumentos técnicos y considero muy viable su eliminación, dejo la decisión final en pausa hasta comentarlo con mi compañero.

**Prompt**

en machine learning qué mide el skewness

**Respuesta IA** `Gemini Flash Lite 3.5 en Gemini`

En machine learning y estadística, el skewness (o asimetría) mide el grado de distorsión o falta de simetría en la distribución de los datos con respecto a su media.
En términos sencillos, te indica si los datos están ”sesgados”hacia un lado o si se distribuyen de forma uniforme y simétrica (como la clásica campana de Gauss).
Los 3 tipos de Skewness
Tipo de Asimetría Valor del Skewness Significado Relación Media/Mediana
Simétrica Igual a 0 (o muy cercano) La distribución es perfectamente equilibrada en ambos lados. Media = Mediana = Moda
Positiva (A la derecha) Mayor que 0 ($> 0$) La cola larga de la distribución se extiende hacia los valores más altos (derecha). La mayoría de los datos se concentran en valores bajos. Media >Mediana >Moda
Negativa (A la izquierda) Menor que 0 ($< 0$) La cola larga se extiende hacia los valores más bajos (izquierda). La mayoría de los datos se concentran en valores altos. Media <Mediana <Moda
¿Por qué es crucial en Machine Learning?
Muchos algoritmos de machine learning asumen que las variables predictoras (features) tienen una distribución normal (simétrica). Medir el skewness es el primer paso para corregirlo por las siguientes razones:
1. Afecta a los modelos lineales: Modelos como la Regresión Lineal, Regresión Logística o el Análisis de Discriminante Lineal (LDA) pierden mucha precisión si los datos están muy sesgados.
2. Impacto de los Outliers: Un skewness alto suele indicar la presencia de valores atípicos (outliers) en las colas largas, lo que puede distorsionar el entrenamiento.
3. Inestabilidad en algoritmos basados en distancia: Algoritmos como KNN o K-Means pueden verse afectados si una variable tiene una escala comprimida por el sesgo.
¿Cómo se soluciona en el pipeline de datos?
Cuando detectas un skewness alto (generalmente mayor a |1| o |0,5| según el criterio), se aplican transformaciones matemáticas para normalizar los datos antes de entrenar el modelo:
• Para skewness positivo: Transformación logarítmica (log(x)), raíz cuadrada (sqrt(x)) o la transformación Box-Cox.
• Para skewness negativo: Transformación exponencial o elevar al cuadrado ($x^2$).
Si estás analizando un conjunto de datos en este momento, cuéntame: ¿qué tipo de datos estás evaluando (ej. ingresos, edades, precios) o qué algoritmo de machine learning planeas utilizar? Así podré recomendarte la mejor estrategia de

transformación.

**Análisis**

Se acepta la explicación de qué mide el skewness, aunque no queda claro por qué mi compañero considera 0.5 como el límite para clasificar el límite de asimetría.

**Prompt**

```
if n_outliers > 0 or abs(skew) > 0.8:
    outlier_skew_list.append(
        {
            "Variable": col,
            "Nº Outliers": n_outliers,
            "% Outliers": pct_outliers,
            "Skewness": skew,
            "Tipo Asimetría": (
                "Positiva (Cola dcha)"
                if skew > 0.5
                else (
                    "Negativa (Cola izq)"
                    if skew < -0.5
                    else "Simétrica (~Normal)"
                )
            ),
        }
    )
```

Cámbiame este código y pon estos límites mejor:
In the interpretation it is stated - following Bulmer (1979) - that: Ïf skewness is less than $-1$ or greater than $+1$, the distribution is highly skewed. If skewness is between $-1$ and $-½$ or between $+½$ and $+1$, the distribution is moderately skewed. If skewness is between $-½$ and $+½$, the distribution is approximately symmetric.”

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

Aquí tienes el código adaptado con la regla clásica de Bulmer (1979).

He ajustado tanto la condición de entrada abs(skew) > 0.5 (para capturar cualquier variable que deje de ser aproximadamente simétrica) como la categorización en los 5 casos posibles (altamente sesgada, moderadamente sesgada
o simétrica, tanto a la izquierda como a la derecha):

```
# Según Bulmer (1979):
# - |skew| > 1: Altamente sesgada
# - 0.5 < |skew| <= 1: Moderadamente sesgada
# - |skew| <= 0.5: Aproximadamente simétrica

if n_outliers > 0 or abs(skew) > 0.5:
    if skew > 1:
        tipo_asimetria = "Altamente sesgada (Positiva / Cola dcha)"
    elif 0.5 < skew <= 1:
        tipo_asimetria = "Moderadamente sesgada (Positiva / Cola dcha)"
    elif -1 <= skew < -0.5:
```

```
        tipo_asimetria = "Moderadamente sesgada (Negativa / Cola izq)"
    elif skew < -1:
        tipo_asimetria = "Altamente sesgada (Negativa / Cola izq)"
    else:
        tipo_asimetria = "Aproximadamente simétrica"

    outlier_skew_list.append(
        {
            "Variable": col,
            "Nº Outliers": n_outliers,
            "% Outliers": pct_outliers,
            "Skewness": round(skew, 3),
            "Tipo Asimetría": tipo_asimetria,
        }
    )

Cambios aplicados:

1.  Condición de filtrado: Se cambió abs(skew) > 0.8 por abs(skew) > 0.5.
Si
    dejas 0.8, estarías ignorando variables con sesgo moderado (entre 0.5
    y 0.8)
    que no tengan outliers detectados.
2.  Estructura clara de decisión: Se sustituyó el ternario anidado por un
bloque
    if/elif/else mucho más legible y fiel a la literatura estadística.
3.  Redondeo: Se añadió un round(skew, 3) para presentar el valor en el
reporte
    o tabla de forma más limpia.
```

**Análisis**

Se cambia la interpretación del valor del skewness que había antes por una interpretación oficial. Dada esta nueva clasificación incluida en el prompt, la IA implementó la nueva clasificación correctamente. Se acepta.

**Prompt**

```
frecuencia_ejercicio_semanal (Numérico): Días a la semana con actividad
física moderada o intensa.

nivel_actividad (Nominal): Grado habitual de actividad física diaria.
Valores posibles: 'Sedentario', 'Ligeramente activo', 'Moderadamente
activo', 'Muy activo'.

Tengo estas dos variables en mi dataset. ¿Crees que ambas variables se
refieren a lo mismo o se podrían estar refiriendo a actividades
diferentes, como la actividad física en el día a día, por ejemplo,
trabajando, frente a ejercicio y deporte?
```

**Respuesta IA** Gemini Flash Lite 3.5 en Gemini

¡Tienes toda la razón en tu intuición! Aunque ambas variables están relacionadas con el movimiento y el esfuerzo físico, **se refieren a dimensiones diferentes** y complementarias de la actividad física.

No son redundantes; de hecho, en estudios epidemiológicos, de salud o de ciencia de datos, es muy común encontrar ambas por separado porque capturan realidades distintas del estilo de vida de una persona.

---

### Diferencia clave entre ambas variables

* **`frecuencia_ejercicio_semanal` (Ejercicio estructurado):**
Mide la **intencionalidad y el tiempo de ocio dedicado al deporte o entrenamiento**. Cuenta los días en que la persona realiza una actividad física planificada (como ir al gimnasio, salir a correr, nadar, jugar al fútbol o asistir a clases dirigidas).
* **`nivel_actividad` (Actividad global / Estilo de vida):**
Mide el **gasto energético total derivado de la rutina diaria** (a menudo asociado al concepto de *PAL - Physical Activity Level* o al NEAT). Esto incluye no solo el ejercicio, sino también el tipo de trabajo (si es de oficina sentado o de pie cargando peso), las tareas domésticas, los desplazamientos a pie o en bicicleta y el movimiento espontáneo a lo largo del día.

---

### Ejemplos prácticos para entenderlo

Para ver por qué son distintas, imagina estos dos perfiles típicos en un dataset:

* **Perfil 1 (Oficinista deportista):** Trabaja sentado frente a un ordenador 8 horas al día, pero es muy disciplinado y va al gimnasio o sale a correr **4 días a la semana**.
* *`frecuencia_ejercicio_semanal`* = `4`
* *`nivel_actividad`* = Podría ser *"Ligeramente activo"* o *"Moderadamente activo"* (el resto del día es sedentario).

* **Perfil 2 (Trabajador de la construcción o repartidor):** Trabaja todo el día de pie, caminando y cargando peso de forma activa, pero nunca va al gimnasio ni hace deporte en su tiempo libre (**0 días de ejercicio planificado**).
* *`frecuencia_ejercicio_semanal`* = `0`
* *`nivel_actividad`* = Podría ser *"Muy activo"* debido al esfuerzo físico constante de su jornada laboral.

```
---

### ¿Por qué es útil tener ambas en un dataset?

Tener las dos variables permite a los modelos (o a los analistas)
distinguir entre el **ejercicio recreativo/saludable** y la **carga
física ocupacional o de estilo de vida**, los cuales tienen impactos
diferentes en la salud, el metabolismo y el gasto calórico total.
```

**Análisis**

En relación con saber si las variables frecuencia_ejercicio_semanal y nivel_actividad se refieren a lo mismo o a cosas diferentes, la IA distinguió ambas dimensiones (ejercicio estructurado y planificado frente a gasto energético global o actividad ocupacional/diaria) y aportó ejemplos claros para justificarlo. Aunque es una respuesta en principio a tomar en cuenta, se debe discutir este asunto con el equipo para adoptar una solución de interpretación definitiva. Esta consulta únicamente sirve para tener una primera opinión al respecto.

**Prompt**

y qué ocurre con los sedentarios que hacen 7 días? Según la descripción de las variables, se deberían considerar valores incoherentes o son actividades físicas diferentes?

**Respuesta IA** Gemini Flash Lite 3.5 en Gemini

```
¡Qué excelente observación! Has dado en el clavo con un dilema clásico de
**calidad de datos (*Data Quality*)** y validación lógica en ciencia de
datos y salud.

En la práctica, encontrarte con un perfil que indica `nivel_actividad =
'Sedentario'` pero una `frecuencia_ejercicio_semanal = 7` (entrenar todos
los días) abre dos escenarios muy claros:

---

### 1. Una incoherencia o error de datos (Lo más probable)

En la gran mayoría de cuestionarios de salud estandarizados (como el IPAQ
- *International Physical Activity Questionnaire*), el **nivel de
actividad global** se calcula sumando el gasto energético total, donde el
ejercicio estructurado aporta una cantidad masiva de puntos (METs).

Si el dataset asigna la etiqueta *"Sedentario"* basándose en una
puntuación global o en una escala donde el ejercicio cuenta, esta
combinación es **metodológicamente imposible**. Suele deberse a:
```

```
* **Errores de auto-reporte:** Las personas suelen sobreestimar su
ejercicio ("voy al gimnasio 7 días" aunque sea 10 minutos a mirar el
móvil) o malinterpretan las preguntas del formulario.
* **Contradicciones en la fuente:** Inconsistencias lógicas introducidas
al fusionar bases de datos o por errores humanos en la digitalización de
encuestas.

### 2. Una separación estricta de dominios (Caso muy atípico pero real)

Si el cuestionario o dataset fue diseñado para aislar completamente el
**trabajo/rutina diaria** del **tiempo libre**, teóricamente podría
ocurrir.

* *Imagina a un teletrabajador extremo:* Pasa 12 horas al día sentado
frente al ordenador programando o teletrabajando (lo que clasifica su día
a día puramente laboral/cotidiano como *"Sedentario"*), pero por
disciplina militar sale a correr o hace estiramientos intensos **todos
los días del año** (7 días de ejercicio).
* Fisiológicamente es posible, pero en términos de estilo de vida general,
llamarlo "sedentario" resulta confuso porque alguien que entrena 7 días a
la semana difícilmente encaja en el concepto clínico de sedentarismo.

---

### ¿Cómo deberías manejar esto si estás analizando el dataset?

Si estás limpiando los datos para un análisis o un modelo de Machine
Learning, esta combinación debe tratarse como una **alerta de anomalía**:

1. **Haz una tabulación cruzada (*crosstab*):** Cruza ambas variables en
una tabla para ver cuántos casos caen en esta combinación (por ejemplo,
¿cuántos "sedentarios" hay con 5, 6 o 7 días de ejercicio?). Si son
muchos, hay un problema en la definición de las variables o en cómo se
recolectó la información.
2. **Criterio de limpieza (Imputación o Filtrado):** Dependiendo de tu
objetivo, podrías reclasificar a estos perfiles como "Moderadamente
activos" o "Muy activos" (dado que 7 días de ejercicio anulan el
sedentarismo real), o bien marcarlos como valores atípicos (*outliers*)
para eliminarlos si corrompen la lógica del modelo.
```

**Análisis**

Se le pregunta a la IA sobre un caso que genera cierta ambigüedad (ser sedentario con 7 días de actividad física moderada o intensa). Aunque la IA se inclina a considerarlo una incoherencia, no descarta que se deba a medir dominios separados. Ante la falta de una conclusión cerrada, se comentará con el equipo para decidir una solución.

**Prompt**

comprueba en un df['anos_fumador'] en python cuál es la cantidad de decimales más grande. Es un float

**Respuesta IA** Gemini Flash Lite 3.5 en Gemini

Para comprobar cuál es la cantidad máxima de decimales en una columna de tipo float (df['anos_fumador']) en Pandas, puedes utilizar dos enfoques principales según tus necesidades:

Opción 1: Método rápido (manipulación de strings)
Este método es ideal si tus datos no contienen notación científica. Convierte los valores a texto, los divide por el punto decimal, elimina los ceros finales sobrantes y calcula la longitud máxima.

Python

```
import pandas as pd

# Calcula el número máximo de decimales ignorando valores nulos (NaN)
max_decimales = (
    df['anos_fumador']
    .dropna()
    .astype(str)
    .str.split('.')
    .str[1]
    .str.rstrip('0')
    .str.len()
    .max()
)

print(f"Cantidad máxima de decimales: {max_decimales}")
```

Opción 2: Método robusto (con la librería decimal)
Si tu DataFrame contiene números en notación científica (por ejemplo, 1.2e-5) o necesitas una precisión matemática absoluta al analizar los exponentes, la librería estándar decimal es la opción más segura:

Python

```
from decimal import Decimal
import pandas as pd

max_d = 0
for val in df['anos_fumador'].dropna():
    try:
        d = Decimal(str(val))
        exp = d.as_tuple().exponent
        decimals = -exp if exp < 0 else 0
        if decimals > max_d:
            max_d = decimals
    except Exception:
        pass
```

```
print(f"Cantidad máxima de decimales (con Decimal): {max_d}")
Explicación rápida:
dropna(): Evita errores si hay valores nulos (NaN) en la columna.

rstrip('0') / Exponentes: Evitan que se cuenten como decimales reales los
ceros innecesarios al final (por ejemplo, tratar 10.0 como 0 decimales en
lugar de 1)
```

**Análisis**

El programa es correcto y se acepta. Se elige la primera opción, que es más simple.

**Prompt**

```
D. Discordancia de comorbilidad vs fármaco:

¿Toma antihipertensivos sin diagnóstico de hipertensión?

farmaco_sin_diag_hta = ( (df["uso_antihipertensivos"] == 1) &
(df["hipertension_previa"] == 0) ).sum() print( f"7. Uso de
antihipertensivos
sin diagnóstico previo de HTA: {farmaco_sin_diag_hta} casos" ) 7. Uso de
antihipertensivos sin diagnóstico previo de HTA: 478 casos

Qué mira esto? Son valores que están mal en mi dataset?
```

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

```
No significa necesariamente que estén mal.

Ese bloque de código está buscando pacientes que declaran tomar
medicación para
la tensión (uso_antihipertensivos == 1), pero en su historial figura que
no
tienen diagnóstico de hipertensión (hipertension_previa == 0).

Que tengas 478 casos así se debe habitualmente a una de estas dos razones
(una
médica y otra de calidad de datos):

1. La razón médica (Es un dato real y válido)

Los fármacos antihipertensivos (como los IECA, ARA-II o betabloqueantes)
no solo
se recetan para la presión alta. Tienen muchas otras indicaciones
médicas:

  - Protección renal: A los pacientes con diabetes se les recetan
```

```
    antihipertensivos (como enalapril o losartán) aunque tengan la
    tensión
    perfecta, porque protegen los riñones.
  - Insuficiencia cardíaca o arritmias: Se usan betabloqueantes (como
    bisoprolol) para controlar el ritmo cardíaco, no por ser hipertensos.
  - Profilaxis de migrañas o temblores: Fármacos como el propranolol se
  usan
    para evitar dolores de cabeza crónicos.

Si filtras esos 478 pacientes, probablemente verás que muchos tienen
diabetes_mellitus == 1, problemas renales (clearance_creatinina bajo) o
edad
avanzada. En estos casos, el dato es 100% real.

2. La razón de sesgo de encuesta / recogida de datos (Subdiagnóstico)

Si la base de datos se hizo mediante un cuestionario al paciente:

  - El paciente confunde su estado: Mucha gente piensa: "Como me tomo la
    pastilla y mi tensión ahora da 120/80, ya no soy hipertenso", y
    marcan
    hipertension_previa = 0.
  - Falta de registro formal: El médico le mandó la pastilla de forma
  preventiva
    pero en el sistema nunca se codificó formalmente la etiqueta de
    "Hipertensión esencial".

¿Qué debes hacer con esos 478 casos?

1.  NO LOS BORRES NI LOS CAMBIES A CERO. Si borras 478 filas por esto,
estarías
    destruyendo información muy valiosa sobre pacientes medicados (que
    suelen
    tener más riesgo).
2.  Revisa su presión actual: Si tienen uso_antihipertensivos == 1,
    hipertension_previa == 0, pero ves que su presion_sistolica media es
    de 145
    mmHg o tienen diabetes, confirma la hipótesis de que están enfermos o
    mal
    controlados.
3.  Decisión para el modelo: El algoritmo de Machine Learning (como
XGBoost o
    Random Forest) es capaz de gestionar esto sin problema. Simplemente
    aprenderá que el hecho de tomar el fármaco (uso_antihipertensivos ==
    1) es
    una señal de riesgo por sí misma, independientemente de la casilla de
    diagnóstico.

En resumen: No es un error grave de tipo "persona con 300 años" o
"presión
```

```
diastólica mayor que sistólica". Es una inconsistencia clínica común en
la
práctica médica real y debes conservarla.
```

**Análisis**

Al ver que se consideraba en el EDA 478 casos como incorrectos, se consultó a la IA para validarlo. La respuesta es coherente y determina que no es un error de datos. Al consultarlo con mi compañero, se decidió no aplicar ninguna modificación a estos registros.

**Prompt**

```
esto es una buena forma de saber si alguien tiene diabetes y no ha sido
diagnosticada?
# E. Diabetes no diagnosticada (HbA1c >= 6.5% o Glucosa >= 126 mg/dL sin
DM previa)
diabetico_oculto = (
    (df["diabetes_mellitus"] == 0)
    & ((df["hemoglobina_glicosilada"] >= 6.5) | (df["glucosa_ayunas"] >=
    126))
).sum()
print(
    f"7. Criterio de diabetes analítica no diagnosticada previamente:
    {diabetico_oculto} casos"
)
```

**Respuesta IA** Gemini Flash Lite 3.5 en Gemini

```
Sí, es una excelente aproximación analítica basada en los criterios
diagnósticos oficiales de la Asociación Americana de Diabetes (ADA) y la
Organización Mundial de la Salud (OMS).

¿Por qué es médicamente correcta?

Los umbrales que utilizas son los estándar de referencia para el
diagnóstico de diabetes:

Hemoglobina glicosilada (HbA1c) $\ge 6.5\%$: Refleja el promedio de
glucosa en sangre de los últimos 3 meses. Un valor igual o superior a
este porcentaje indica diabetes.

Glucosa en ayunas $\ge 126\text{ mg/dL}$ (en ausencia de ingesta calórica
previa de al menos 8 horas): Es el segundo criterio analítico principal.

df["diabetes_mellitus"] == 0: Filtra correctamente a los pacientes que no
tienen un diagnóstico previo registrado, cumpliendo con la definición
exacta de "diabetes no diagnosticada" u oculta.
```

Sin embargo, ten en cuenta estas limitaciones clínicas (para que tu análisis sea más robusto):

La regla de la confirmación: En la práctica clínica real, un solo valor alterado de glucosa en ayunas o HbA1c no basta para dar el diagnóstico definitivo. Los protocolos médicos exigen una repetibilidad (repetir la prueba en un segundo análisis o usar otra métrica confirmatoria) a menos que existan síntomas clásicos de hiperglucemia (poliuria, polidipsia, pérdida de peso inexplicable).

Tu código identifica correctamente a los casos "con sospecha analítica fuerte", pero en epidemiología se suele hablar de casos que cumplen criterios de cribado.

El ayuno estricto: Para la glucosa en ayunas, asegúrate de que los datos del dataset provengan realmente de pacientes en ayunas, ya que una comida previa puede elevar puntualmente la glucosa sin que signifique diabetes.

Interferencias en la HbA1c: Ciertas condiciones (como hemoglobinopatías, anemias severas, insuficiencia renal crónica o embarazos) pueden alterar los valores de la HbA1c dando falsos positivos o negativos.

Conclusión

Tu código es matemáticamente preciso y conceptualmente riguroso para un análisis de datos o estudio epidemiológico sobre un dataset. Si estás preparando un informe, puedes presentar esta métrica con confianza, aclarando que se trata de casos que cumplen con los criterios analíticos de laboratorio para diabetes sin un diagnóstico previo registrado en el sistema.

**Análisis**

Al ver que mi compañero marcaba 597 casos como pacientes con diabetes sin detectar, procedo a verificar si la comprobación es correcta. Aunque dice ser datos oficiales de la OMS, necesito corraborarlo con fuentes, puesto que supondría una modificación de alreredor del 25 % de la columna de diabetes.

**Prompt**

pero los valores utilizados estan avalados por fuentes?

**Respuesta IA** Gemini Flash Lite 3.5 en Gemini

Sí, están 100% avalados por las principales organizaciones médicas del mundo.

```
Los valores que utilizaste en tu código ($\text{HbA1c} \ge 6.5\%$ y
$\text{Glucosa en ayunas} \ge 126\text{ mg/dL}$) son los criterios
estándar internacionales de diagnóstico respaldados por las máximas
autoridades en endocrinología y salud pública.

Las fuentes de referencia oficiales:

American Diabetes Association (ADA): En sus guías anuales de práctica
clínica (Standards of Care in Diabetes), la ADA establece explícitamente
estos dos cortes exactos para el diagnóstico de diabetes.

Organización Mundial de la Salud (OMS): Define los mismos umbrales en sus
manuales globales de diagnóstico y clasificación de la diabetes mellitus.

Grupo de Trabajo Internacional de Expertos en HbA1c: Recomienda
formalmente el uso de la hemoglobina glicosilada ($\ge 6.5\%$) como punto
de corte para diagnosticar la enfermedad sin necesidad de realizar
pruebas de glucosa orales adicionales.

Guías de Práctica Clínica del Ministerio de Sanidad (y homólogos
internacionales): Adaptan íntegramente estos mismos valores para los
protocolos de salud pública y atención primaria.

Resumen de los puntos de corte oficiales:

Estado,Glucosa en Ayunas,Hemoglobina Glicosilada (HbA1c)

Normal,<100 mg/dL,<5.7%

Prediabetes,100–125 mg/dL,5.7%–6.4%

Diabetes (Tu código), 126 mg/dL, 6.5%

Puedes incluir las guías de la ADA (Standards of Care) o los documentos
de la OMS en las citas o notas al pie de tu proyecto con total
tranquilidad técnica y científica.
```

**Análisis**

Aunque me vuelve a insistir que los datos están 100 % avalados y me proporciona más fuentes de referencia oficiales que usan este criterio, sigo sin aceptar la respuesta de la IA, ya que supone un cambio enorme a una columna del dataset.

**Prompt**

pasame enlace de una fuente para verlo

**Respuesta IA** Gemini Flash Lite 3.5 en Gemini

```
Aquí tienes el enlace directo al capítulo oficial de las Guías de
Práctica Clínica de la American Diabetes Association (ADA):

ADA Standards of Care: 2. Diagnosis and Classification of Diabetes

¿Dónde verlo directamente en el documento?

Dentro del enlace, si vas a la Tabla 2.1 (Criteria for the Diagnosis of
Diabetes), verás exactamente los siguientes umbrales:

A1C $\ge 6.5\%$ ($\ge 48\text{ mmol/mol}$)

Fasting Plasma Glucose (FPG) $\ge 126\text{ mg/dL}$ ($\ge 7.0\text{
mmol/L}$) - definiendo ayuno como ausencia de ingesta calórica durante al
menos 8 horas.

También puedes revisar el resumen para pacientes directamente en el
portal de la American Diabetes Association (Diabetes.org).
```

**Análisis**

Para terminar de confirmar que el código para detectar diabetes se puede aceptar, pido enlace a fuentes directas. Al revisarlas, puedo confirmar que es correcto.

**Prompt**

pero esta bien con diabetes mellitus? o es un tipo diferente

**Respuesta IA** Gemini Flash Lite 3.5 en Gemini

```
Sí, está perfectamente bien. La Diabetes Mellitus Tipo 2 representa la
inmensa mayoría de estos casos en la práctica clínica y epidemiológica.

Los umbrales que usaste ($\text{HbA1c} \ge 6.5\%$ y $\text{Glucosa en
ayunas} \ge 126\text{ mg/dL}$) son universales para diagnosticar el
estado metabólico de Diabetes Mellitus, pero no diferencian por sí solos
qué tipo de diabetes tiene el paciente.

¿Por qué tu código aplica correctamente para Diabetes Mellitus?

La inmensa mayoría son Tipo 2: En adultos y en análisis de datos
poblacionales, más del 90-95% de los casos de diabetes no diagnosticada
son Diabetes Mellitus Tipo 2. Es una enfermedad de desarrollo lento y
silencioso (asintomática durante años), por lo que es la que se detecta
en este tipo de cribados analíticos.
```

```
La Diabetes Tipo 1 rara vez es "oculta": La Diabetes Tipo 1 suele debutar
de forma aguda con síntomas muy severos y rápidos (cetoacidosis,
deshidratación grave), por lo que los pacientes acuden a urgencias y se
diagnostican de inmediato, raramente permaneciendo como un "caso oculto"
en un dataset de control de rutina.

Mismos criterios analíticos iniciales: Las guías clínicas (ADA/OMS)
aplican exactamente los mismos valores de glucosa y HbA1c para confirmar
el estado de hiperglucemia diabética en la Tipo 1, Tipo 2 o diabetes
secundaria.

Cómo se diferencian en la práctica médica

Si quisieras precisar exactamente el tipo de diabetes en la clínica, se
requieren pruebas adicionales que no suelen ser de rutina en un análisis
de sangre básico:

Tipo,Proporción típica,¿Por qué ocurre?,¿Cómo se diferencia en
laboratorio?
Diabetes Tipo 2,~90-95%,Resistencia a la insulina y deficiencia
relativa.,"C-péptido normal/alto, anticuerpos negativos, relacionada con
IMC/edad."
Diabetes Tipo 1,~5%,Destrucción autoinmune de las células beta del
páncreas.,"Anticuerpos positivos (anti-GAD, IA-2, ICA) y C-péptido muy
bajo o nulo."
LADA / LADA 1.5,~1-3%,Autoinmune de inicio lento en
adultos.,"Inicialmente parece Tipo 2, pero presenta anticuerpos
autoinmunes positivos."

Si tu dataset etiqueta la variable como diabetes_mellitus (que es el
término médico general), tu lógica es totalmente válida y rigurosa. Si
quieres afinar la redacción de tus hallazgos, puedes describirlos como
"Casos que cumplen criterios analíticos para Diabetes Mellitus
(predominantemente Tipo 2 no diagnosticada)".
```

**Análisis**

Al notar que el enunciado se refería específicamente a la diabetes mellitus tipo 2 y no a la diabetes en general, pregunté si el código seguía siendo correcto. Aunque olvidé especificar el tipo 2 en mi mensaje, la IA lo interpretó correctamente en su respuesta, por lo que el código se dio por aceptado.

**Prompt**

```
y esto es correcto para comprobar que los datos del dataset son malos?
pasame una fuente para comprobarlo
1. DISCORDANCIA ANTROPOMÉTRICA (IMC vs Perímetro de Cintura)
Obesidad grado II/III (IMC > 35) con cintura de persona delgada (< 70 cm)
o viceversa
incoherencia_antropo = (
```

```
    ((df["indice_masa_corporal"] > 35) & (df["perimetro_cintura"] < 70))
    | ((df["indice_masa_corporal"] < 18.5) & (df["perimetro_cintura"] >
    110))
).sum()
print(
    f"\n 2. Inconsistencia severa entre IMC y Perímetro de cintura:
    {incoherencia_antropo} casos"
)
1. DISCORDANCIA GLUCOSA vs HEMOGLOBINA GLICOSILADA
HbA1c normal (<5.5%) con Glucosa diabética severa (>180 mg/dL) o
viceversa
incoherencia_glucemica = (
    ((df["hemoglobina_glicosilada"] < 5.5) & (df["glucosa_ayunas"] >
    180))
    | ((df["hemoglobina_glicosilada"] > 9.0) & (df["glucosa_ayunas"] <
    80))
).sum()
print(
    f"\n 3. Incoherencia metabólica cruzada (Glucosa vs HbA1c):
    {incoherencia_glucemica} casos"
)
```

**Respuesta IA** Gemini Flash Lite 3.5 en Gemini

Sí, es una excelente estrategia técnica. En análisis de datos e informática médica, esto se denomina detección de inconsistencias lógicas o biológicas cruzadas (cross-validation of biological plausibility). Tu código no solo demuestra que hay errores en los datos, sino que identifica imposibilidades fisiológicas o errores de transcripción/medición extremos.

¿Por qué son correctas tus reglas lógicas?

1. Incoherencia Antropométrica (IMC vs. Cintura)

IMC > 35 con Cintura < 70 cm: Salvo en casos extremadamente raros de fisicoculturistas con una masa muscular extrema (e incluso en ellos la cintura rara vez baja de 70 cm con 35 de IMC), es biológicamente incompatible tener una masa corporal compatible con Obesidad Grado II/III y un contorno abdominal de un adulto marcadamente delgado.

IMC < 18.5 con Cintura > 110 cm: El perímetro abdominal $\ge 110\text{ cm}$ indica obesidad abdominal severa según la OMS. Es físicamente imposible tener una cintura de ese tamaño y mantener un peso global tan bajo como para dar un IMC de bajo peso ($< 18.5$).

2. Incoherencia Glucémica (Glucosa en Ayunas vs. HbA1c)

```
HbA1c < 5.5% con Glucosa > 180 mg/dL: La HbA1c refleja el promedio de la
glucosa de los últimos 2-3 meses. Un valor de HbA1c de 5.5% corresponde a
una glucosa promedio estimada (eAG) de unos $111\text{ mg/dL}$. Una
glucosa puntual en ayunas de $> 180\text{ mg/dL}$ (hiperglucemia severa)
en alguien con promedio normal sostenido solo ocurriría en eventos de
estrés glucémico agudo extremo o administración de fármacos en urgencias,
pero en un dataset de control/cribado rutinario indica casi con certeza
un error de digitación o falta de ayuno.

HbA1c > 9.0% con Glucosa < 80 mg/dL: Una HbA1c de $9.0\%$ implica una
glucosa media diaria de $\approx 212\text{ mg/dL}$. Encontrar una glucosa
basal de $< 80\text{ mg/dL}$ es extremadamente improbable a menos que el
paciente haya recibido una dosis masiva de insulina justo antes de la
toma de muestra (o sea una muestra mal procesada donde la glucosa se haya
degradado por hemólisis en el tubo de ensayo).

Fuentes médicas y científicas oficiales para justificarlo

Para justificar estas reglas de limpieza de datos en la memoria o informe
de tu proyecto, puedes citar estas dos referencias oficiales:

Para la Incoherencia Antropométrica:

Fuente: World Health Organization (WHO) Guidelines & Technical Report
Series (Obesity: preventing and managing the global epidemic).

Enlace directo: WHO Guidelines: Waist Circumference and Waist-Hip Ratio

Justificación: La OMS establece la correlación directa entre el
incremento de la circunferencia de la cintura y el IMC para clasificar el
riesgo cardiometabólico. La desviación extrema entre ambos refleja error
de medición.

Para la Incoherencia Glucémica (Relación HbA1c y Glucosa Promedio):

Fuente: ADA Standards of Care in Diabetes (Table: Correlation of A1C with
Estimated Average Glucose - eAG).

Enlace directo: ADA Standards of Care: Diabetes Care Journal
```

**Análisis**

Al no estar seguro de si ambas comprobaciones eran correctas (aunque ya conocía el rango de IMC entre 35 y 70), le pedí a la IA que las verificara con fuentes fiables. Tras revisar la información proporcionada, se dieron por aceptadas.

**Prompt**

Quiero comprobar en mi df qué variables tienen varianza cercana a 0. Para ello, quiero que uses estas dos métricas de forma conjunta:

el ratio entre la frecuencia del valor más frecuente y la frecuencia del segundo valor más frecuente (ratio de frecuencia): 1 para variables balanceadas, grande para variables mal balanceadas.
el porcentaje de valores únicos sobre el total objetos, que se aproximará cero a medida que la granularidad de la variable aumenta.

**Respuesta IA** Gemini Flash Lite 3.5 en Gemini

```
Para identificar qué variables en tu DataFrame tienen una varianza
cercana a 0 (también conocido en Machine Learning como características de
*cuasi-cero varianza* o *near-zero variance*, similar al enfoque del
paquete `caret` en R), puedes implementar una función en Python que
calcule ambas métricas de forma conjunta.

### Definición de las métricas

1. **Ratio de frecuencia:** Mide el desequilibrio entre el valor más
frecuente y el segundo más frecuente
($\frac{\text{Frecuencia}_1}{\text{Frecuencia}_2}$). Si la variable está
perfectamente equilibrada, tiende a 1; si es casi constante, este número
se dispara (o se vuelve infinito si solo existe un valor único).
2. **Porcentaje de valores únicos:** Mide la granularidad calculando qué
tanto porcentaje representan los valores únicos frente al total de filas
($\frac{\text{Valores únicos}}{\text{Total de filas}} \times 100$). En
variables constantes o con muy poca variabilidad, este porcentaje se
aproxima a 0.

---

### Código en Python

Puedes utilizar la siguiente función para analizar tu DataFrame (`df`):

```python
import pandas as pd
import numpy as np

def detectar_baja_varianza(df, freq_ratio_umbral=19,
unique_pct_umbral=10):
    """
    Identifica variables con varianza cercana a 0 usando el ratio de
    frecuencia
    y el porcentaje de valores únicos.

    Parámetros:
    - df: DataFrame de pandas a analizar.
    - freq_ratio_umbral: Umbral mínimo para considerar el ratio
    desequilibrado (por defecto 19:1).
    - unique_pct_umbral: Umbral máximo del porcentaje de valores únicos
    sobre el total (por defecto 10%).
```
```

```
    """
    resultados = []
    n_filas = len(df)

    for col in df.columns:
        # Contar frecuencias de cada valor (incluyendo nulos si se desea
        evaluar su peso)
        conteo_valores = df[col].value_counts(dropna=False)

        if len(conteo_valores) == 0:
            continue

        n_unicos = len(conteo_valores)
        pct_unicos = (n_unicos / n_filas) * 100

        # Calcular el ratio de frecuencia
        if n_unicos >= 2:
            freq_1 = conteo_valores.iloc[0]
            freq_2 = conteo_valores.iloc[1]
            # Evitar división por cero si la frecuencia del segundo es 0
            freq_ratio = freq_1 / freq_2 if freq_2 > 0 else np.inf
        else:
            # Si solo hay 1 valor único (columna 100% constante)
            freq_ratio = np.inf

        resultados.append({
            'variable': col,
            'n_unicos': n_unicos,
            'porcentaje_unicos': pct_unicos,
            'ratio_frecuencia': freq_ratio,
            'valor_mas_frecuente': conteo_valores.index[0],
            'freq_valor_mas_frecuente': conteo_valores.iloc[0]
        })

    df_metricas = pd.DataFrame(resultados)

    # Filtrar aquellas variables que cumplen ambas condiciones de baja
    varianza
    df_baja_var = df_metricas[
        (df_metricas['ratio_frecuencia'] > freq_ratio_umbral) &
        (df_metricas['porcentaje_unicos'] < unique_pct_umbral)
    ].reset_index(drop=True)

    return df_metricas, df_baja_var

# Ejemplo de uso:
# metricas_completas, columnas_baja_varianza = detectar_baja_varianza(df)
# print(columnas_baja_varianza)

```
```
```

```
### ¿Cómo interpretar los resultados?

* **Variables descartables por baja varianza:** Aquellas donde el
`ratio_frecuencia` supere un umbral estricto (por ejemplo, mayor a `19`,
lo que significa que el valor más común aparece al menos 19 veces más que
el segundo) **Y** cuyo `porcentaje_unicos` sea extremadamente bajo (por
ejemplo, menor al `10%`).
* **Valores infinitos (`inf`):** Si una columna tiene un único valor en
todo el DataFrame (variable completamente constante), el segundo valor no
existe, por lo que el `ratio_frecuencia` se registrará como `inf` y el
porcentaje de únicos será cercano a 0 (`1 / n_filas`), detectándose de
forma inmediata como un caso crítico de varianza cero.
```

**Análisis**

En la consulta se pide que se realice un código para calcular la varianza cercana a 0 como se indica en los apuntes. El código es correcto con ls dos métricas que se indica. Sin embargo, no estoy de acuerdo con utilizar los valores nulos, ya que se están contando como un valor más y aparecer como el valor con más frecuencia. Tampoco me gusta que no se impriman los valores ni que esté considerando el target. Por lo tanto, se acepta el código pero para usarlo de base y hacerle modificaciones. No estoy seguro sobre el valor de los dos límites establecidos.

**Prompt**

lo de los dos límites no me convencen. No has seguido ningún criterio ni ningún estándar

**Respuesta IA** Gemini Flash Lite 3.5

```
¡Qué va! Lejos de ser una ocurrencia al azar, esos dos números
específicos (`19` y `10`) responden a un **estándar muy conocido y
consolidado en Machine Learning y ciencia de datos**: las heurísticas del
paquete **`caret` de R**, diseñado por Max Kuhn (autor de referencia y
coautor de *Applied Predictive Modeling*).

Este enfoque se creó precisamente para solucionar el problema de las
variables de **cuasi-cero varianza** (*near-zero variance* o NZV).

Los criterios detrás de estos números son los siguientes:

* **El ratio de frecuencia = 19 (la regla del 95/5):**
Equivale a un desequilibrio donde el valor más frecuente aparece **19
veces más** que el segundo valor más frecuente (es decir, una
distribución aproximada del 95% frente al 5%). Max Kuhn estableció
empíricamente este umbral para detectar variables donde una categoría
domina abrumadoramente y aporta poquísima información útil al modelo.
* **El porcentaje de valores únicos < 10%:**
```

`Actúa como una red de seguridad para medir la granularidad. Ayuda a distinguir variables que, aunque tengan múltiples valores, están tan concentrados en muy pocas categorías o rangos que su variedad real es mínima frente al tamaño total del dataset (`n_filas`).`

**Análisis**

Lejos de pensar que estos valores son al azar, la IA me demuestra que los límites establecidos son parte de un estándar muy consolidado (el cual al investigar nearZeroVar de caret se pudo comprobar que vienen dichos valores por defecto), por lo que se acepta la sugerencia.