# Prompts y respuestas IA

Álvaro Arcís Reverte y Alejandro Nicolás Navarro

Máster Universitario en Inteligencia Artificial
Curso 2026–2027

**Prompt**

Prepara un archivo README inicial, teniendo en cuenta lo pedido.

**Respuesta IA** Claude Code (Claude Opus 5.5), CLI en Windows

```
# Predicción Multiclase de Riesgo Cardiovascular en Población Adulta
> **Máster Universitario en Inteligencia Artificial - Universidad de
Murcia (UMU)**
> **Asignatura:** Machine Learning | **Curso:** 2026/2027
> **Colaboración clínica:** Hospital Morales Meseguer

---

##   Descripción del Proyecto

Las enfermedades cardiovasculares representan una de las principales
causas de morbimortalidad a nivel global. Este proyecto tiene como
objetivo diseñar, entrenar y evaluar modelos predictivos de Machine
Learning capaces de clasificar con alta precisión y fiabilidad clínica el
nivel de riesgo cardiovascular en una cohorte adulta de **2.254
pacientes**.

La variable objetivo (`riesgo_cardiovascular`) contempla tres niveles de
estratificación:
* **Clase 0:** Bajo Riesgo
* **Clase 1:** Riesgo Moderado
* **Clase 2:** Alto Riesgo

El repositorio recoge el flujo de trabajo end-to-end: desde el análisis
exploratorio de datos (EDA) y la mitigación de problemáticas de calidad
del dato (imputación, outliers, desbalanceo, escalado), hasta el ajuste
de hiperparámetros, validación cruzada y comparación estadística de
clasificadores base y ensambles.

---

##   Integrantes del Equipo

| Nombre y Apellidos | Usuario de GitHub | Correo Institucional |
| :--- | :--- | :--- |
| *[Nombre Miembro 1]* | `@usuario1` | `usuario1@um.es` |
| *[Nombre Miembro 2]* | `@usuario2` | `usuario2@um.es` |
| *[Nombre Miembro 3]* | `@usuario3` | `usuario3@um.es` |

---

##   Estructura del Repositorio

El proyecto se organiza bajo una estructura modular orientada a la
reproducibilidad científica:
```

```text
  data/
      raw/                          # Dataset original
(enfermedad_cardiovascular.csv)
      processed/                    # Datasets limpios o transformados (si
aplica)
  docs/                             # Documentación técnica y entregables
      memoria_tecnica.pdf           # Memoria técnica maquetada (máx. 15
páginas)
      uso_etico_ia.pdf              # Registro de prompts y reflexión
crítica de IA
      video_link.txt                # Enlace al vídeo explicativo (máx. 7
min)
  notebooks/                        # Jupyter Notebooks de desarrollo y
análisis
      01_eda_calidad_datos.ipynb # Análisis exploratorio y detección de
problemáticas
      02_preprocesamiento.ipynb  # Transformaciones, codificación e
imputación
      03_modelado_evaluacion.ipynb# Entrenamiento, ajuste de
hiperparámetros y métricas
      04_test_estadisticos.ipynb # Comparación estadística de modelos
(opcional)
  src/                              # Código fuente refactorizado y
reutilizable
      __init__.py
      data_loader.py                # Carga y comprobación de integridad
      preprocessing.py             # Pipelines de preprocesamiento
(Scikit-Learn)
      models.py                     # Definición y pipelines de algoritmos
      evaluation.py                 # Cálculo de métricas y matrices de
confusión
  .gitignore                        # Filtro de ficheros innecesarios
  environment.yml                   # Configuración del entorno Conda
(alternativa)
  requirements.txt                  # Fichero de dependencias fijadas
(versiones exactas)
  README.md                         # Documento principal del repositorio
```

**Análisis**

README inicial preparado, incluyendo descripción del proyecto, integrantes, estructura de carpetas y archivos. Se rellena con los datos de los miembros y la estructura del proyecto se cambiará.

**Prompt**

```
lee el proyecto y recomiendame una estructura para los archivos, crea los
archivos y las carpetas necesarias, pero ni se te ocurra resolverlos, e
incluye esta interacción al Uso_IA
```

**Respuesta IA** Claude Code (Claude Opus 5.5), CLI en Windows

```
Tras leer el enunciado, las instrucciones de entrega, el dataset y el
README, propuso y creó la siguiente estructura (solo esqueletos vacíos,
sin resolver ningún apartado):

- data/raw/            -> se movió aquí enfermedad_cardiovascular.csv
(git mv)
- data/processed/      -> vacío (.gitkeep)
- notebooks/           -> 01_eda, 02_preprocesamiento, 03_modelado,
04_evaluacion, 05_test_estadisticos (.ipynb), cada uno solo con títulos
de sección y celdas "# TODO"
- src/                 -> __init__, config, data_loader, preprocessing,
models, evaluation, statistical_tests (.py), solo con un docstring que
describe su responsabilidad y "TODO"
- results/figures/, results/tables/, models/ -> vacíos (.gitkeep)
- docs/decisiones.md   -> tabla para registrar decisiones de diseño y
avances
- docs/memoria/, docs/uso_etico_ia/ -> vacíos (.gitkeep)
- docs/video.md        -> plantilla para el enlace del vídeo
- requirements.txt     -> vacío, con instrucciones para rellenarlo con
pip freeze
- .gitignore           -> entornos virtuales, cachés, checkpoints,
modelos y auxiliares de LaTeX
- README.md            -> se rellenó la sección "Estructura del
Repositorio" y se añadió una sección "Reproducción" pendiente
```

**Análisis**

Se prepara la estructura de carpetas y archivos del proyecto, incluyendo los esqueletos vacíos para cada sección para facilitar la organización y el desarrollo posterior.

Conversación Alejandro para el EDA:
**[Ver conversación interactiva completa (HTML renderizado)]**

**Análisis**

En el enlace se sitúa la conversación mantenida con el LLM para la resolución de problemáticas de calidad del dato, incluyendo prompts, respuestas resumidas y análisis crítico.

**Prompt**

en visual studio code (.ipynb) cuando muestro, por ejemplo, un dataframe, se cortan las columnas o las filas a mitad y lo mismo ocurre con los print largos. Cómo puedo ver la salida completa?

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

Este problema ocurre por dos razones: las limitaciones propias de Pandas (para
no colapsar la memoria) y las limitaciones de la interfaz de VS Code (para no
ralentizar el editor).

Aquí tienes las soluciones para ambos casos:

1. Para DataFrames de Pandas (Filas y Columnas cortadas)

Pandas viene configurado por defecto para truncar tablas grandes. Puedes cambiar
esta configuración ejecutando esto en una celda al principio de tu notebook:

```
import pandas as pd

# Mostrar todas las columnas
pd.set_option('display.max_columns', None)

# Mostrar todas las filas (¡Cuidado si tienes millones de filas!)
pd.set_option('display.max_rows', None)

# Mostrar el contenido completo de cada celda (que no corte el texto largo)
pd.set_option('display.max_colwidth', None)
```

Consejo Pro para VS Code:
VS Code tiene un visor de datos integrado excelente.

1. Haz clic en el botón "Variables" en la barra superior del notebook (al lado
   de "Clear All Outputs").
2. Busca tu DataFrame y haz clic en el icono pequeño que parece una tabla a la
   izquierda del nombre de la variable.
   Se abrirá una pestaña interactiva donde puedes ordenar, filtrar y ver todos
   los datos sin recortar.

2. Para salidas de texto largas (print())

```
Si haces un print() muy largo, VS Code a veces corta el texto o le pone
una
barra de desplazamiento molesta.

Opción A: Desactivar el scroll (Hacer que se vea todo hacia abajo)

1.  Pasa el cursor por el margen izquierdo de la celda de salida (al lado
de
    donde aparece el texto).
2.  Haz clic en los tres puntos (...) que aparecen o haz clic derecho
sobre la
    salida.
3.  Selecciona "Toggle Output Scrolling" (Alternar desplazamiento de
salida).
    Esto expandirá la celda para que muestre todo el texto en lugar de
    recortarlo en una ventanita pequeña.

Opción B: Cambiar el límite de líneas en la configuración de VS Code

Por seguridad, VS Code limita el texto plano a unas 100 líneas por celda
para no
trabarse. Puedes aumentarlo:

1.  Ve a Configuración: Ctrl + , (en Windows/Linux) o Cmd + , (en Mac).
2.  En la barra de búsqueda escribe: notebook text line limit.
3.  Busca la opción: Notebook > Output: Text Line Limit.
4.  Aumenta el número (por defecto suele ser 100, puedes poner 500, 1000
o más).

3. Solución rápida en código para un print puntual

Si solo quieres imprimir un texto muy largo o un DataFrame como texto
completo
una sola vez sin cambiar la configuración global:

# Para DataFrames:
print(df.to_string())

# Para textos gigantes (evitar que la UI se congele guardándolo en un
archivo temporal):
with open("salida.txt", "w", encoding="utf-8") as f:
    f.write(str(tu_variable_gigante))
# Y luego lo abres directamente en VS Code con Ctrl+O
```

**Análisis**

Se acepta el código para poder visualizar los dataframes que pandas corta por defecto, dejándolo como código para descomentar si se necesita.

**Prompt**

cómo se lee una matriz de correlación? hay diferencia a la hora de analizar correlacion entre variables y entre la variable target?

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

```
Para entender una matriz de correlación sin perderte, la regla de oro es
dividirla en dos zonas completamente distintas:

1.  La relación entre tus variables predictoras y el TARGET (la fila o
columna
    de la variable a predecir).
2.  La relación entre las variables predictoras ENTRE SÍ (el resto de
celdas de
    la matriz).

Lo que en una zona es excelente, en la otra puede ser un problema grave.

Lo básico: ¿Qué significa el número? (Coeficiente de -1 a 1)

  - Cercano a 1 (Positivo fuerte): Se mueven en la misma dirección. Si el
  valor
    de una variable sube, el de la otra también tiende a subir.
  - Cercano a -1 (Negativo fuerte): Se mueven en direcciones opuestas. Si
  el
    valor de una variable sube, el de la otra tiende a bajar (relación
    inversa).
  - Cercano a 0: No hay relación lineal/monótona. Lo que le ocurra a una
    variable no nos dice absolutamente nada sobre el comportamiento de la
    otra.

Zona 1: Variables Predictoras vs. TARGET

Aquí buscas responder: ¿Esta variable me sirve para predecir lo que
quiero
estimar?

  - ¿Qué buscas aquí? Quieres números lo más alejados de 0 posible (tanto
    fuertemente positivos como fuertemente negativos).
      - Un valor alto positivo indica un factor de riesgo o acelerador
      directo.
      - Un valor alto negativo indica un factor protector o freno directo.
      Ambos
        son igual de útiles para el algoritmo.
  - ¿Cuándo es "malo" aquí?
      - Cuando el valor está muy cerca de 0.00.
      - Significa que esa variable, de forma aislada, apenas tiene poder
      de
        asociación con el target. Si todas las variables de un dataset
        tuvieran
```

```
        correlación cercana a 0 con el objetivo, el modelo difícilmente
        aprendería un patrón útil.

Zona 2: Variables Predictoras ENTRE SÍ

Aquí buscas responder: ¿Tengo variables repetidas que aportan la misma
información?

  - ¿Qué buscas aquí? En general, en Machine Learning, quieres números
  cercanos
    a 0 (variables independientes entre sí). Esto garantiza que cada
    columna
    aporta un dato nuevo y distinto al conjunto.
  - ¿Cuándo es "malo" aquí?
      - Cuando dos variables predictoras tienen una correlación muy alta
      entre
        sí (típicamente superior a 0.80 o inferior a -0.80). Este
        fenómeno se
        conoce como Multicolinealidad.
      - ¿Por qué es un problema la multicolinealidad?
        1.  Confunde a ciertos modelos (especialmente lineales como
        Regresión
            Lineal o Logística): Los algoritmos no pueden distinguir a
            cuál de
            las dos variables atribuirle el peso en la predicción,
            volviendo los
            coeficientes matemáticos muy inestables.
        2.  Introduce redundancia innecesaria: Estás duplicando
        información sin
            ganar capacidad predictiva, aumentando el coste computacional
            del
            modelo.

Resumen visual: ¿Qué buscar en cada parte de la matriz?

| Zona de la Matriz         | Lo ideal (Lo que quieres ver)
| Lo problemático (Lo que debes vigilar)
|
| :------------------------ |
:-------------------------------------------------------------------------------------
|
:-------------------------------------------------------------------------------------
|
| **Variable vs. Target**   | **Lejos de 0** (valores altos positivos o
negativos, ej. $> 0.25$ o $< -0.25$). Indican buena capacidad para
predecir el objetivo. | **Cerca de 0** (ej. entre $-0.05$ y $0.05$). La
variable no aporta información relevante de forma individual para
predecir el target. |
```

```
| **Variable vs. Variable** | **Cerca de 0** (habitualmente entre $-0.30$
y $0.30$). Cada variable mide aspectos distintos e independientes.
| **Muy cerca de 1 o -1** (magnitudes $> 0.80$). Hay variables
redundantes (**Multicolinealidad**) que pueden desestabilizar el modelo.
|
```

## Análisis

Se acepta la explicación de la tabla de correlación y la explicación de valores a tener en cuenta entre variables vs variables y variables vs target.

## Prompt

```
# ------------------------------------------------------------------------------
# 1. MATRIZ DE CORRELACIÓN DE SPEARMAN (NUMÉRICAS + TARGET)
# ------------------------------------------------------------------------------
plt.figure(figsize=(18, 14))
corr_matrix = df[NUM_COLS + [TARGET_COL]].corr(method="spearman")
mask = np.triu(np.ones_like(corr_matrix, dtype=bool))

sns.heatmap(
    corr_matrix,
    mask=mask,
    cmap="vlag",
    center=0,
    annot=True,
    fmt=".2f",
    annot_kws={"size": 8},
    linewidths=0.5,
    cbar_kws={"shrink": 0.8},
)
plt.title(
    "Matriz de Correlación de Spearman (Variables Numéricas y Target)",
    fontsize=14,
    fontweight="bold",
    pad=15,
)
plt.show()

# ------------------------------------------------------------------------------
# 2. TOP VARIABLES NUMÉRICAS CON MAYOR PODER DISCRIMINATORIO EMPÍRICO
# ------------------------------------------------------------------------------
# Calculamos la correlación de Spearman de cada variable numérica con el target
# y seleccionamos las 8 de mayor magnitud absoluta (positivas o protectoras/negativas)
corr_with_target = df[NUM_COLS].corrwith(df[TARGET_COL], method="spearman")
top_features = corr_with_target.abs().sort_values(ascending=False).head(8).index

print("=" * 70)
print(
    "TOP 8 VARIABLES NUMÉRICAS MÁS ASOCIADAS EMPÍRICAMENTE AL RIESGO CARDIOVASCULAR"
)
print("=" * 70)
for feat in top_features:
    r_val = corr_with_target[feat]
    tipo = "Factor de Riesgo (+)" if r_val > 0 else "Factor Protector (-)"
    print(f" • {feat:28s}: Spearman r = {r_val:+.3f}  ({tipo})")

# Visualización mediante Boxplots estratificados por nivel de riesgo
fig, axes = plt.subplots(2, 4, figsize=(18, 11))
axes = axes.flatten()

class_labels_short = ["0 (Bajo)", "1 (Moderado)", "2 (Alto)"]

for idx, col in enumerate(top_features):
```

```
    r_val = corr_with_target[col]
    sns.boxplot(
        x=TARGET_COL,
        y=col,
        data=df,
        ax=axes[idx],
        palette="Blues",
        hue=TARGET_COL,
        legend=False,
    )
    axes[idx].set_title(
        f"{col}\n(Spearman r = {r_val:+.2f})", fontsize=11, fontweight="bold"
    )
    axes[idx].set_xlabel("Nivel de Riesgo Cardiovascular")
    axes[idx].set_xticklabels(class_labels_short)
    axes[idx].set_ylabel(col)

plt.suptitle(
    "Distribución de las 8 Variables Numéricas más Correlacionadas empíricamente",
    y=1.02,
    fontsize=14,
    fontweight="bold",
)
plt.tight_layout()
plt.show()
```

No es un poco innecesario este codigo por volver a calcular las correlacion de spearman si ya tienes la matriz de correlación de antes? o es mejor porque es más preciso?

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

Tienes toda la razón: es completamente innecesario y redundante. No es más
preciso en absoluto; el cálculo matemático y el resultado numérico son exactamente los mismos.

¿Por qué es redundante?

En el paso 1 ya calculaste la matriz completa:

```
corr_matrix = df[NUM_COLS + [TARGET_COL]].corr(method="spearman")
```

Dentro de corr_matrix, la columna (o fila) correspondiente a TARGET_COL ya
contiene exactamente la correlación de Spearman de cada variable numérica con el
target.

Volver a ejecutar df[NUM_COLS].corrwith(...) en el paso 2 obliga a pandas a
volver a ordenar (rankear) todos los datos y recalcular las operaciones matemáticas desde cero, lo cual:

1. Desperdicia tiempo de cómputo (Spearman requiere ordenar los datos, lo que
   en datasets medianos/grandes es costoso).

```
2.  Viola el principio DRY (Don't Repeat Yourself).

Cómo simplificarlo

Puedes reemplazar esa línea extrayendo directamente la serie de la matriz
que ya
calculaste:

#
------------------------------------------------------------------------------
# 2. TOP VARIABLES NUMÉRICAS CON MAYOR PODER DISCRIMINATORIO EMPÍRICO
#
------------------------------------------------------------------------------
# En lugar de recalcular con .corrwith():
# corr_with_target = df[NUM_COLS].corrwith(df[TARGET_COL],
method="spearman")

# Simplemente extraes la columna del target para las variables numéricas:
corr_with_target = corr_matrix.loc[NUM_COLS, TARGET_COL]

top_features =
corr_with_target.abs().sort_values(ascending=False).head(8).index

El resto de tu código funcionará exactamente igual, pero de forma más
limpia,
idiomática y eficiente.
```

**Análisis**

Al notar que la correlación se calculaba dos veces y dudar de si aportaba mayor precisión, se confirmó con esta consulta que el segundo cálculo era redundante e innecesario, pasando a extraer los valores directamente de la matriz previa para simplificar el código.

**Prompt**

```python
for idx, col in enumerate(top_features):
    r_val = corr_with_target[col]
    sns.boxplot(
        x=TARGET_COL,
        y=col,
        data=df,
        ax=axes[idx],
        palette= "Blues",
        hue=TARGET_COL,
        legend=False,
    )
```

Haz que la paleta sea roja si la correlación es positiva y azul si es negativa.

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

Aquí tienes el bucle modificado. Puedes asignar dinámicamente la paleta ("Reds" si es positiva o "Blues" si es negativa) evaluando el valor de r_val:

```
for idx, col in enumerate(top_features):
    r_val = corr_with_target[col]

    # Paleta dinámica: Rojo si aumenta el riesgo (+), Azul si es
    protector (-)
    palette_color = "Reds" if r_val > 0 else "Blues"

    sns.boxplot(
        x=TARGET_COL,
        y=col,
        data=df,
        ax=axes[idx],
        palette=palette_color,
        hue=TARGET_COL,
        legend=False,
    )
    axes[idx].set_title(
        f"{col}\n(Spearman r = {r_val:+.2f})", fontsize=11,
        fontweight="bold"
    )
    axes[idx].set_xlabel("Nivel de Riesgo Cardiovascular")
    axes[idx].set_xticklabels(class_labels_short)
    axes[idx].set_ylabel(col)
```

¿Qué hace este cambio?

- Si r > 0 (Factor de Riesgo): utiliza la gama "Reds", donde los niveles de
  riesgo van subiendo en tonos de rojo.
- Si r \le 0 (Factor Protector): utiliza la gama "Blues", manteniendo la
  escala de azules.

**Análisis**

Se acepta la sugerencia, pero sin hacer la variable auxiliar.

**Prompt**

Tengo una base de datos sobre Predicción Multiclase de Riesgo Cardiovascular en
Población Adulta para clasificar a los pacientes en tres niveles de riesgo
cardiovascular (Clase 0: Bajo Riesgo, Clase 1: Riesgo Moderado y Clase 2: Alto
Riesgo). Las variables son:

edad (Numérico): Edad del paciente expresada en años cumplidos.

presion_sistolica (Numérico): Presión arterial sistólica medida en reposo (mmHg).

presion_diastolica (Numérico): Presión arterial diastólica medida en reposo
(mmHg).

colesterol_total (Numérico): Nivel de colesterol total en suero (mg/dL).

colesterol_hdl (Numérico): Nivel de colesterol de alta densidad o 'colesterol
bueno' (mg/dL).

colesterol_ldl (Numérico): Nivel de colesterol de baja densidad o 'colesterol
malo' (mg/dL).

trigliceridos (Numérico): Concentración sérica de triglicéridos (mg/dL).

glucosa_ayunas (Numérico): Nivel de glucosa en sangre tras ayuno nocturno (mg/dL).

indice_masa_corporal (Numérico): Índice de masa corporal calculado como peso/talla$^2$ (kg/m$^2$).

frecuencia_cardiaca_reposo (Numérico): Frecuencia cardíaca medida en reposo
(latidos por minuto).

horas_sueno_diarias (Numérico): Promedio de horas de descanso nocturno declaradas por día.

consumo_alcohol_semanal (Numérico): Unidades de bebida estándar de alcohol
consumidas semanalmente.

anos_fumador (Numérico): Tiempo acumulado de exposición al tabaco expresado en
años.

proteina_c_reactiva (Numérico): Concentración de proteína C reactiva ultrasensible (mg/L).

acido_urico (Numérico): Nivel sérico de ácido úrico (mg/dL).

clearance_creatinina (Numérico): Tasa de filtrado glomerular / depuración de
creatinina (mL/min).

```
frecuencia_ejercicio_semanal (Numérico): Días a la semana con actividad
física
moderada o intensa.

perimetro_cintura (Numérico): Circunferencia abdominal medida en
centímetros.

hemoglobina_glicosilada (Numérico): Porcentaje de hemoglobina glicosilada
HbA1c
en sangre (%).

fumador_actual (Booleano): Indica el hábito tabáquico activo (1: Sí, 0:
No).

hipertension_previa (Booleano): Diagnóstico previo confirmado de
hipertensión
arterial (1: Sí, 0: No).

diabetes_mellitus (Booleano): Diagnóstico previo de diabetes mellitus
tipo 2 (1:
Sí, 0: No).

tratamiento_estatinas (Booleano): Uso habitual de fármacos
hipolipemiantes /
estatinas (1: Sí, 0: No).

uso_antihipertensivos (Booleano): Uso habitual de medicamentos para el
control
presivo (1: Sí, 0: No).

tipo_alimentacion (Nominal): Patrón dietético principal del paciente.
Valores
posibles: 'Mediterránea', 'Occidental', 'Vegetariana', 'Baja en
carbohidratos'.

nivel_actividad (Nominal): Grado habitual de actividad física diaria.
Valores
posibles: 'Sedentario', 'Ligeramente activo', 'Moderadamente activo',
'Muy
activo'.

antecedentes_familiares_tipo (Nominal): Presencia de eventos
cardiovasculares en
familiares de primer grado. Valores posibles: 'Ninguno', 'Materno',
'Paterno',
'Ambos'.

riesgo_cardiovascular (Objetivo): Variable target de clasificación en 3
categorías (0: Bajo riesgo, 1: Riesgo moderado, 2: Alto riesgo).
```

Quiero que me digas valores en los que suelen estar estas variables y qué errores sería conveniente revisar.

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

Para preparar adecuadamente esta base de datos antes de entrenar un modelo de
Machine Learning, es fundamental validar tanto los rangos clínicos plausibles
como la coherencia lógica entre variables.

A continuación, tienes una guía detallada dividida en dos partes: rangos de
referencia y errores/inconsistencias clave a revisar.

1. Rangos de Valores Típicos y Plausibles

A continuación se presentan los valores divididos en rangos normales, rangos
habituales en la práctica clínica y límites extremos que indicarían un posible
error de captura:

| Variable | Rango Normal / Óptimo
| Rango Típico en Adultos | Alerta: Posible Error de Datos
|
| :---------- | :----------
| :---------- |
:---------- |
| **edad** | 18 - 65 años
| 18 - 95 años | $< 18$ (si es solo adultos) o $> 110$
|
| **presion_sistolica** | 90 - 120 mmHg
| 100 - 180 mmHg | $< 70$ (shock) o $> 240$ mmHg
|
| **presion_diastolica** | 60 - 80 mmHg
| 60 - 110 mmHg | $< 40$ o $> 140$ mmHg
|
| **colesterol_total** | $< 200$ mg/dL
| 130 - 320 mg/dL | $< 80$ o $> 500$ mg/dL
|
| **colesterol_hdl** | $> 40$ (hombres) / $> 50$
(mujeres) | 25 - 85 mg/dL | $< 15$ o $> 120$ mg/dL
|
| **colesterol_ldl** | $< 100$ mg/dL
| 70 - 220 mg/dL | $< 30$ o $> 350$ mg/dL
|

```
| **trigliceridos**                  | $< 150$ mg/dL
| 60 - 350 mg/dL          | $< 30$ o $> 1000$ mg/dL
|
| **glucosa\_ayunas**                | 70 - 99 mg/dL
| 70 - 250 mg/dL          | $< 40$ (hipoglucemia severa) o $> 400$ mg/dL
|
| **indice\_masa\_corporal**         | 18.5 - 24.9 kg/m²
| 18 - 45 kg/m²           | $< 13$ o $> 65$ kg/m²
|
| **frecuencia\_cardiaca\_reposo**   | 60 - 100 lpm
| 50 - 110 lpm            | $< 35$ o $> 180$ lpm
|
| **horas\_sueno\_diarias**          | 7 - 9 horas
| 4 - 10 horas            | $< 2$ o $> 16$ horas
|
| **consumo\_alcohol\_semanal**      | 0 - 7 (mujeres) / 0 - 14 (hombres)
| 0 - 30 UBEs\*           | $< 0$ o $> 80$ UBEs semanales
|
| **anos\_fumador**                  | 0 años
| 0 - 50 años             | $< 0$ o mayor que `edad - 10`
|
| **proteina\_c\_reactiva (PCR)**    | $< 1.0$ mg/L (bajo riesgo)
| 0.1 - 10 mg/L           | $> 20$ mg/L (suele indicar infección aguda,
no riesgo vascular basal) |
| **acido\_urico**                   | 3.5 - 7.2 mg/dL
| 2.5 - 10 mg/dL          | $< 1.5$ o $> 15$ mg/dL
|
| **clearance\_creatinina**          | 90 - 130 mL/min
| 30 - 140 mL/min         | $< 5$ o $> 200$ mL/min
|
| **frecuencia\_ejercicio\_semanal** | 3 - 5 días
| 0 - 7 días              | $< 0$ o $> 7$ días
|
| **perimetro\_cintura**             | $< 80$ (mujeres) / $< 94$
(hombres) | 65 - 130 cm             | $< 45$ o $> 180$ cm
|
| **hemoglobina\_glicosilada**       | 4.0% - 5.6%
| 4.5% - 11%              | $< 3.5\%$ o $> 16\%$
|

*UBE = Unidad de Bebida Estándar (aprox. 1 caña de cerveza, 1 copa de
vino o 1
chupito).

2. Errores de Coherencia Cruzada (Cruciales para Limpieza)

En variables médicas, los datos pueden estar individualmente en rango,
pero ser
fisiológicamente imposibles o contradictorios al compararlos entre sí:
```

```
A. Presión Arterial

  - Error crítico: presion_diastolica >= presion_sistolica. La sistólica
  siempre
    debe ser superior.
  - Presión de pulso no plausible: La diferencia (presion_sistolica -
    presion_diastolica) rara vez es menor a 20 mmHg o mayor a 100 mmHg en
    reposo.

B. Coherencia en el Perfil Lipídico

  - Ecuación de Friedewald: En condiciones normales, el colesterol total
  se
    aproxima con:
    \text{Colesterol Total} \approx \text{LDL} + \text{HDL} +
    (\text{Triglicéridos} / 5)
    Si la suma de \text{LDL} + \text{HDL} supera ampliamente al
    colesterol_total, hay un error de registro.

C. Tabaco y Edad

  - anos_fumador >= edad: Imposible.
  - anos_fumador > (edad - 10): Muy poco probable (indicaría que empezó a
  fumar
    con menos de 10 años).
  - Contradicción de hábito: Pacientes con fumador_actual == 0 pero
  anos_fumador
    > 0 representan ex-fumadores (esto es correcto, pero conviene
    definirlo);
    sin embargo, fumador_actual == 1 con anos_fumador == 0 suele ser un
    error (a
    menos que haya empezado hace menos de un año).

D. Diabetes y Glucemia

  - Si diabetes_mellitus == 0, pero hemoglobina_glicosilada >= 6.5% y
    glucosa_ayunas >= 126 mg/dL, es probable que el paciente sea un
    diabético no
    diagnosticado o haya un error en la etiqueta binaria.
  - Si diabetes_mellitus == 1, pero tiene glucosa_ayunas y
    hemoglobina_glicosilada en rangos extremadamente bajos sin
    medicación,
    convendría revisarlo.

E. Hipertensión y Medicación

  - Pacientes con uso_antihipertensivos == 1 que tienen
  hipertension_previa == 0
    (raro, salvo uso off-label para otras patologías como migraña o
    insuficiencia cardíaca).
```

```
F. Actividad Física

  - Inconsistencia entre nivel_actividad == 'Sedentario' y
    frecuencia_ejercicio_semanal >= 5.
  - Inconsistencia entre nivel_actividad == 'Muy activo' y
    frecuencia_ejercicio_semanal == 0.

G. Antropometría (IMC vs. Cintura)

  - Un indice_masa_corporal > 35 (obesidad moderada/severa) acompañado de
  un
    perimetro_cintura < 70 cm indica casi con seguridad un error en las
    unidades
    (por ejemplo, registrar la cintura en pulgadas en lugar de
    centímetros).

3. Buenas Prácticas adicionales para tu Modelo

1.  Codificación de Variables Nominales:
      - antecedentes_familiares_tipo y tipo_alimentacion deben tratarse
      con
        One-Hot Encoding.
      - nivel_actividad tiene un orden intrínseco (Sedentario \to
      Ligeramente
        \to Moderadamente \to Muy activo), por lo que un Ordinal Encoding
        (0, 1, 2, 3) preservará mejor esa jerarquía.
2.  Distribución del Target (riesgo_cardiovascular):
      - Comprueba el desbalance de clases. En salud, la Clase 2 (Alto
      Riesgo)
        suele tener muchas menos muestras que la Clase 0. Si hay
        desbalance
        severo, evalúa métricas como Macro F1-Score o PR-AUC multiclase
        en lugar
        de Accuracy, y utiliza técnicas como SMOTE o ponderación de
        clases
        (class_weight='balanced').
3.  Valores Nulos Encubiertos:
      - Busca números como -1, 999 o 0 en variables como
      clearance_creatinina,
        horas_sueno_diarias o presion_sistolica, que a veces se
        introducen en
        bases de datos hospitalarias para indicar "no registrado".
```

**Análisis**

En cuanto a esta propuesta inicial de la IA para detectar problemáticas y establecer algunos rangos para detectar valores erróneos o atípicos, hay opinión dividida. Por una parte, se aceptan y se toman en cuenta algunas propuestas sobre valores y rangos a comprobar. Algunos ya los habíamos tenido en cuenta, como puede ser

comprobar si hay menores de edad en los ejemplos o comprobar que el consumo de alcohol semanal no es negativo, pero algunos otros son propuestas interesantes que no se habían tenido en cuenta, aunque falta comprobar si comprobación tienen sentido. También revela una fórmula por la cual se relacionan los dos tipos de colesterol y el colesterol total, revelando que también la columna *trigliceridos* actúa. Sin embargo, se descartan algunas propuestas como marcar ciertos valores extremos como errores, ya que eliminar valores atípicos pueden ser valores valiosos para poder aprender a detectar el riesgo alto, y más si es un problema en el ámbito de la medicina. Habrá que determinar qué valores atípicos conservar.

**Prompt**

Muchas de las variables que me has indicado como una alerta de posible error,si estoy haciendo un modelo para predecir el riesgo cardiovascular, no crees que son interesantes mantenerlas porque esos atípicos podrían ayudar a ser el detonante para detectar el riesgo?

**Respuesta IA** Gemini Flash 3.8 en Google AI Studio

```
Es una observación completamente acertada y muy perspicaz desde el punto
de
vista clínico. En medicina, los eventos graves (infartos, ictus) suelen
ocurrir
precisamente en la "cola" de la distribución: el paciente que tiene 210
mmHg de
tensión sistólica o 9.5% de hemoglobina glicosilada es exactamente el que
debe
clasificarse como Alto Riesgo (Clase 2).

Eliminar estos valores a ciegas ("tratar los outliers" de forma estándar)
arruinaría la capacidad predictiva del modelo.

Sin embargo, hay una diferencia crítica entre dos tipos de valores
extremos. El
objetivo no es borrar datos por ser altos, sino distinguir el riesgo
extremo del
"ruido biológicamente imposible" o del "ruido de confusión".

Aquí tienes cómo diferenciar lo que debes conservar de lo que debes
corregir o
descartar:

1. Lo que DEBES mantener (Atípicos Clínicos / Señales de Alto Riesgo)

Son valores muy elevados, pero compatibles con la vida y directamente
causantes
de daño cardiovascular. No los elimines ni los recortes
(capping/winsorizing) si
```

```
vas a usar modelos basados en árboles:

  - Presión sistólica de 190 - 220 mmHg: Es una crisis o urgencia
  hipertensiva.
    Es un predictor brutal de riesgo cardiovascular inminente.
  - Triglicéridos de 500 - 1000 mg/dL: Se asocia a hipertrigliceridemia
  severa
    (y riesgo de pancreatitis además de cardiovascular).
  - Glucosa en ayunas de 250 - 350 mg/dL o HbA1c de 11 - 13%: Diabetes
    gravemente descompensada; genera aterosclerosis acelerada.
  - Clearance de creatinina de 15 - 30 mL/min: Insuficiencia renal
  avanzada; la
    enfermedad renal crónica es uno de los mayores multiplicadores de
    riesgo
    cardiovascular conocidos.
  - IMC de 45 - 55: Obesidad mórbida grado III, factor de riesgo masivo.

2. Lo que DEBES corregir o eliminar (Errores que engañan al algoritmo)

Aquí el valor atípico no representa "más riesgo", sino un fallo en la
toma o
registro del dato. Si dejas estos valores, el modelo aprenderá patrones
absurdos:

  - Incompatibilidad física o biológica:
      - Una presion_sistolica de 320 mmHg o 30 mmHg en un paciente
      ambulatorio.
        A 320 revienta una arteria cerebral al instante; a 30 la persona
        está en
        parada cardiorrespiratoria, no haciéndose un chequeo de
        prevención.
      - presion_diastolica (p. ej., 110) mayor que la sistolica (p. ej.,
      90):
        Error humano al teclear la barra espaciadora o intercambiar las
        columnas.
  - Confusión de escalas/unidades (Muy común):
      - glucosa_ayunas con valor 6.5: El médico anotó el dato en mmol/L
      (usado
        en Europa/EE.UU.) en lugar de mg/dL (debería ser ~117 mg/dL). El
        modelo
        interpretará que el paciente tiene glucosa 6.5 mg/dL (estaría
        muerto de
        hipoglucemia).
      - perimetro_cintura de 36: Medido en pulgadas, no en centímetros
      (36
        pulgadas son ~91 cm).
  - Datos "centinela" o nulos camuflados:
      - clearance_creatinina = -1 o 999. Si el algoritmo lo toma como
      número
```

```
        continuo, un 999 parecerá un riñón superhumano cuando en realidad
        era un
        dato faltante.

3. El caso especial de la PCR (Proteína C Reactiva): El "Ruido de
Confusión"

La proteina_c_reactiva es el mejor ejemplo de por qué hay que tener
cuidado:

  - En riesgo cardiovascular se utiliza la PCR ultrasensible (PCR-us):
      - Bajo riesgo: < 1 mg/L
      - Riesgo moderado: 1 - 3 mg/L
      - Riesgo alto: > 3 mg/L (hasta unos 10 mg/L)
  - ¿Qué pasa si un paciente tiene PCR de 80 mg/L? No significa que tenga
  8
    veces más riesgo cardíaco que uno de 10. Significa que ese día tenía
    una
    neumonía, una infección bacteriana o una apendicitis. Si dejas ese
    valor sin
    contexto, el modelo puede asumir que una inflamación sistémica aguda
    es la
    causa primaria de riesgo cardiovascular a largo plazo, distorsionando
    el
    peso de la variable. Clínicamente, ante una PCR > 20 mg/L, la
    analítica
    cardiovascular suele descartarse y repetirse semanas después.

¿Cómo manejar esto con Machine Learning?

1.  Usa modelos robustos a valores extremos: Si mantienes estos valores
atípicos
    reales (como 210 mmHg de tensión o glucosas de 300), no utilices
    Regresión
    Logística o Redes Neuronales sin escalar, ya que los extremos
    desestabilizan
    los gradientes y coeficientes. Utiliza modelos basados en árboles de
    decisión (XGBoost, LightGBM, Random Forest), ya que a estos modelos
    solo les
    importa el orden de partición (>180 ya es alto, da igual si es 185 o
    240,
    caerán en la misma rama).
2.  Tu filtro no debe ser estadístico (Z\text{-score} > 3), debe ser de
    plausibilidad fisiológica: No quites un dato solo porque se aleje de
    la
    campana de Gauss. Quítalo únicamente si el valor es incompatible con
    que el
    paciente haya llegado caminando a la consulta.
```

**Análisis**

TODO (Aún no he podido verificar si los valores que dice para todas las variables son correctos y si de las variables científicas hay valores que no se pueden dar en el mundo real)

**Prompt**

colesterol hdl valores puede ser negativo?

**Respuesta IA** `Gemini Flash-Lite 3.5 en Gemini`

No, el valor del colesterol HDL (conocido como colesterol "bueno") no puede ser negativo.
• Valores mínimos lógicos: Los niveles de colesterol HDL en la sangre se miden en miligramos por decilitro (mg/dL) y el límite físico inferior es de 0 mg/dL, ya que no existe una cantidad menor de cero.
• Valores considerados bajos:
• En hombres: menos de 40 mg/dL (y se considera muy bajo por debajo de 35 mg/dL).
• En mujeres: menos de 50 mg/dL (y se considera muy bajo por debajo de 40 mg/dL).
• Si has visto un número negativo o extraño en una analítica: Generalmente se debe a un error de transcripción, un fallo en la lectura del equipo del laboratorio, un formato de celda alterado o un código de error informático, y no a que tu organismo tenga un nivel negativo de lipoproteínas.
Consulta con tu médico o con el laboratorio que realizó el análisis para que repitan la lectura o te aclaren la cifra exacta de tu perfil lipídico. Si te han entregado unos análisis recientes, dime:
• ¿Qué valor numérico exacto te aparece?
• ¿Hay otros valores alterados (como los triglicéridos o el colesterol LDL)?
Así podré orientarte mejor sobre lo que significa tu resultado.

**Análisis**

Al encontrarse este valor negativo y dudar de su validez, se aceptó la afirmación de que el colesterol HDL no puede ser biológicamente negativo, estableciendo correctamente el límite inferior en 0 mg/dL.

**Prompt**

y los triglicéridos pueden ser negativos?

**Respuesta IA** `Gemini Flash-Lite 3.5 en Gemini`

No, los triglicéridos no pueden ser negativos. En una analítica de sangre, los resultados miden la cantidad de una sustancia real presente en el organismo, por lo que el valor mínimo posible es cero (0 mg/dL), aunque un nivel de cero absoluto tampoco es biológicamente realista. Si ves un signo de resta o un valor negativo en

tu informe, generalmente se debe a una de las siguientes razones:
• Es un guion o símbolo de separación: A veces, el sistema del laboratorio utiliza un guion antes del número o para separar el nombre de la prueba de su resultado (por ejemplo: Triglicéridos - 85 mg/dL), lo que puede confundirse con un signo ”menos”.
• Un error en el informe impreso: Puede tratarse de una errata tipográfica o un fallo de formato en la visualización del documento.
• Error de laboratorio: En casos extremadamente raros, si el cálculo se realiza de forma automatizada mediante ciertas fórmulas indirectas y otros valores están muy descompensados, el sistema podría arrojar un error técnico.
Para ayudarte a salir de dudas, ¿podrías transcribir exactamente cómo aparece escrito el valor en tu papel, o indicarme el resto de los resultados (como el colesterol total, LDL y HDL)?

**Análisis**

Al encontrarse este valor negativo y dudar de su validez, se aceptó la afirmación de que los triglicéridos no pueden ser biológicamente negativos, estableciendo correctamente el límite inferior en 0 mg/dL. La IA plantea que podría haberse colado un signo menos. Esta hipótesis se podría tener en cuenta a la hora de decidir qué estrategia aplicr con las variables cuyos valores no podían ser negativos, si se determina que realmente ha sido un error al escribir los datos.